Matheus da Silva Marini – Matrícula: 1142514833

Avaliação de técnicas de visão computacional para detecção de defeitos em cartas Pokémon TCG em cenários com baixo volume de dados aplicada à graduação de cartas

São Paulo

2026

Matheus da Silva Marini – Matrícula: 1142514833

Avaliação de técnicas de visão computacional para detecção de defeitos em cartas Pokémon TCG em cenários com baixo volume de dados aplicada à graduação de cartas

Proposta de Trabalho de Conclusão de Curso apresentada ao SENAC Santo Amaro como requisito parcial para aprovação na disciplina de TCC1 do curso de Ciência da Computação.

SENAC – Serviço Nacional de Aprendizagem Comercial
Unidade Santo Amaro
Curso de Ciência da Computação

Orientador: Prof. Afonso Lelis

São Paulo
2026

Resumo

Este documento apresenta a proposta inicial do Trabalho de Conclusão de Curso (TCC1) desenvolvido no SENAC Santo Amaro. O objetivo deste trabalho é comparar estratégias de visão computacional aplicadas à detecção de defeitos superficiais em cartas Pokémon TCG em cenários de baixo volume de dados, identificando quais abordagens apresentam melhor desempenho com conjuntos limitados de imagens anotadas. A justificativa baseia-se na escassez de bases de dados públicas anotadas por especialistas e no alto custo de rotulagem, o que limita o treinamento de modelos tradicionais e motiva o uso de técnicas específicas para poucos exemplos (*small dataset*). Como contexto de aplicação, destaca-se o processo de graduação de cartas, atualmente realizado de forma manual e sujeito à subjetividade. A revisão bibliográfica abrange visão computacional, inspeção visual automatizada, Deep Learning, *transfer learning* e técnicas para treinamento com conjuntos limitados de imagens anotadas. Como solução proposta, pretende-se implementar um pipeline de treinamento e avaliação utilizando a arquitetura YOLO, combinada com técnicas de fotometria e aumento de dados (*data augmentation*), comparando o impacto de diferentes estratégias de treinamento por meio de métricas quantitativas em um *dataset* real de 88 cartas fornecido por uma empresa brasileira especializada em graduação de cartas TCG.

Palavras-chave: Visão Computacional. Detecção de Defeitos. Pokémon TCG. Small Datasets. YOLO.

Sumário

1 INTRODUÇÃO . . . 4
1.1 Contexto . . . 5
1.2 Justificativa . . . 6
1.3 Objetivos . . . 7
1.3.1 Objetivo Geral . . . 7
1.3.2 Objetivos Específicos . . . 7

2 REVISÃO BIBLIOGRÁFICA . . . 8
2.1 Referencial teórico . . . 8
2.1.1 Trading Card Games e o Mercado de Colecionismo . . . 8
2.1.2 Visão Computacional e Inspeção Visual Automatizada . . . 9
2.1.3 Deep Learning e Redes Neurais Convolucionais . . . 9
2.1.4 Desafios Técnicos na Inspeção de Cartas . . . 10
2.2 Metodologia da pesquisa bibliográfica . . . 10
2.3 Fundamentos . . . 11
2.4 Trabalhos relacionados . . . 11
2.4.1 Trabalho 1: [Título do trabalho] . . . 12
2.4.2 Trabalho 2: [Título do trabalho] . . . 12
2.4.3 Trabalho 3: [Título do trabalho] . . . 12

3 DESENVOLVIMENTO . . . 14
3.1 Solução proposta . . . 14
3.2 Cronograma de trabalho . . . 14

REFERÊNCIAS . . . 16

1 Introdução

O mercado de Trading Card Games (TCG), representado por franquias como Pokémon e Magic: The Gathering, deve movimentar aproximadamente 20 bilhões de dólares globalmente em 2026, com projeção de ultrapassar 76 bilhões até 2035 (Business Research Insights, 2026). Nesse mercado, o valor de uma carta está diretamente ligado ao seu estado de conservação (NAHAR et al., 2025). Para certificar essa condição e garantir a segurança das transações, consolidou-se o serviço especializado de graduação de cartas (*grading*). A PSA, fundada em 1991, foi a pioneira em padronizar essa avaliação ao estabelecer uma escala de 10 pontos que se tornaria norma do setor, enquanto a Beckett, em 1999, introduziu subnotas para atributos individuais (SHEN; WEI, 2025). Essa metodologia baseia-se na inspeção de quatro atributos físicos: superfície (*surface*), bordas (*edges*), cantos (*corners*) e centralização (*centering*), sendo a nota final definida pela análise combinada desses fatores (NAHAR et al., 2025).

O processo de graduação, no entanto, ainda é realizado de forma predominantemente manual. Os avaliadores inspecionam cada carta com lupas e iluminação controlada, o que torna a análise demorada e sujeita à subjetividade de cada profissional (NAHAR et al., 2025). Isso limita a capacidade das empresas de escalar o serviço, gerando longas filas de espera para os consumidores. Além disso, o manuseio frequente durante a inspeção representa um risco à carta em si, pois o contato repetido pode causar desgastes que reduzem diretamente a nota do item avaliado (NAHAR et al., 2025). Num mercado onde pequenas diferenças de conservação representam grandes variações de preço, essa inconsistência tem consequências financeiras diretas (NAHAR et al., 2025; WARREN; PIMBBLETT; MBOLI, 2026).

Como consequência dessas limitações, a automação baseada em visão computacional tem sido investigada como alternativa à inspeção manual. Na indústria de manufatura, sistemas de visão computacional já são utilizados para automatizar inspeções de qualidade, empregando arquiteturas de *Deep Learning* e Redes Neurais Convolucionais (CNNs) para detectar defeitos em tempo real (ZHENG et al., 2021). No entanto, adaptar essas abordagens para cartas colecionáveis apresenta desafios específicos. Variações de iluminação e reflexos em superfícies holográficas (*foil*) podem obscurecer defeitos críticos e comprometer a precisão dos modelos (WARREN; PIMBBLETT; MBOLI, 2026). Além disso, o cálculo da centralização depende da detecção precisa das bordas da carta, o que exige tratamento prévio de ruídos visuais para garantir medições consistentes (WARREN; PIMBBLETT; MBOLI, 2026; TIAN; WEI, 2022).

Outro desafio relevante está relacionado à disponibilidade de dados. Em tarefas de detecção de objetos, especialmente em domínios especializados, a obtenção de grandes volumes de dados anotados é limitada, uma vez que esses modelos dependem fortemente

de *datasets* rotulados e a construção de bases de dados anotadas em larga escala é custosa e trabalhosa (SITU et al., 2023). Esse cenário contribui para problemas como *overfitting* e baixa capacidade de generalização dos modelos (PAIANO et al., 2024), motivando o uso de estratégias como *transfer learning*, aumento de dados (*data augmentation*) e abordagens voltadas ao aprendizado com poucos exemplos.

Pesquisadores já investigaram o uso de técnicas de visão computacional para detecção de defeitos no contexto de cartas colecionáveis (WARREN; PIMBBLETT; MBOLI, 2026; NAHAR et al., 2025), porém ainda há uma carência de estudos que avaliem sistematicamente o desempenho de diferentes estratégias em cenários com baixo volume de dados nesse contexto específico. Diante disso, este trabalho propõe uma análise comparativa de estratégias de visão computacional aplicadas à detecção de defeitos em cartas TCG, conduzida sobre um *dataset* composto por 88 cartas fornecido por uma empresa brasileira especializada em graduação. Para isso, será adotado um pipeline experimental baseado na arquitetura YOLO, no qual diferentes estratégias de treinamento serão avaliadas por meio de um estudo de ablação. A partir de um modelo base, serão conduzidos experimentos controlados nos quais técnicas como *transfer learning*, aumento de dados (*data augmentation*) e métodos de pré-processamento como fotometria serão progressivamente incorporadas, permitindo analisar o impacto de cada estratégia no desempenho do modelo. A avaliação será realizada por meio de métricas quantitativas, com o objetivo de identificar as abordagens mais eficazes em cenários com dados limitados.

1.1 Contexto

No processo de graduação de cartas colecionáveis, a avaliação do estado físico é baseada na análise detalhada de atributos visuais como superfície (*surface*), bordas (*edges*), cantos (*corners*) e centralização (*centering*) (NAHAR et al., 2025). Esses atributos estão diretamente relacionados à presença de defeitos, que podem incluir riscos superficiais, desgastes nas bordas (*whitening*), pequenas dobras, marcas de pressão e irregularidades de impressão (NAHAR et al., 2025; WARREN; PIMBBLETT; MBOLI, 2026). Tais imperfeições frequentemente apresentam baixa visibilidade, podendo ocorrer em regiões específicas da carta e com variações sutis de textura e cor (WARREN; PIMBBLETT; MBOLI, 2026). Do ponto de vista computacional, a detecção desses defeitos apresenta desafios relevantes. Muitos defeitos possuem dimensões reduzidas e baixo contraste em relação ao fundo, dificultando sua identificação por modelos de visão computacional. Além disso, superfícies holográficas (*foil*), comuns em cartas de maior valor, introduzem reflexos e variações de iluminação que podem mascarar imperfeições ou gerar ruídos visuais, comprometendo a extração de características relevantes (WARREN; PIMBBLETT; MBOLI, 2026). A própria análise da centralização exige a detecção precisa das bordas da carta, o que depende de técnicas robustas de segmentação e pré-processamento de

imagem (WARREN; PIMBBLETT; MBOLI, 2026; TIAN; WEI, 2022). Em tarefas de visão computacional aplicadas à inspeção visual, abordagens baseadas em aprendizado profundo, como redes neurais convolucionais (CNNs) e modelos de detecção de objetos, têm sido amplamente utilizadas para identificar defeitos em diferentes domínios (ZHENG et al., 2021). No entanto, essas abordagens geralmente dependem de grandes volumes de dados anotados para alcançar bom desempenho (SITU et al., 2023). No contexto de cartas colecionáveis, a construção de *datasets* extensos é limitada, uma vez que a anotação de defeitos exige conhecimento especializado e condições controladas de captura de imagem (NAHAR et al., 2025). Esse cenário caracteriza um problema típico de aprendizado com poucos dados, no qual modelos tendem a sofrer com *overfitting* e baixa capacidade de generalização (PAIANO et al., 2024). Como consequência, torna-se necessário o uso de estratégias específicas, como *transfer learning*, aumento de dados (*data augmentation*) e técnicas de pré-processamento, que buscam melhorar o desempenho dos modelos mesmo com conjuntos reduzidos de treinamento. Compreender o impacto relativo dessas estratégias nesse domínio específico esse cenário motiva a investigação de estratégias específicas para esse domínio.

1.2 Justificativa

A anotação especializada de defeitos em cartas colecionáveis é um processo custoso e dependente de conhecimento técnico específico, o que limita significativamente a construção de bases de dados em larga escala (NAHAR et al., 2025; SITU et al., 2023). Esse cenário torna a investigação de estratégias eficazes para cenários com poucos dados não apenas relevante, mas necessária para viabilizar soluções automatizadas nesse domínio.

No âmbito científico, os estudos existentes sobre automação da graduação de cartas TCG apresentam contribuições relevantes, mas com escopo limitado. Nahar et al. (2025) propõem um modelo baseado em *transfer learning* para graduação de cantos, alcançando 83% de acurácia, porém sobre um conjunto de 593 cartas e restrito a um único atributo de avaliação. Warren, Pimbblett e Mboli (2026) desenvolvem um pipeline híbrido com YOLOv8 para detecção localizada de defeitos, construído sobre um *dataset* de mais de 43.000 amostras obtidas com plataforma robótica proprietária. Nenhum dos dois trabalhos avalia sistematicamente o impacto relativo de diferentes estratégias de treinamento em cenários com conjuntos reduzidos de dados reais, lacuna que este trabalho se propõe a investigar com base em um conjunto real de 88 cartas fornecido por uma empresa brasileira especializada em graduação.

Na prática, os resultados desta investigação podem fornecer orientações concretas para empresas do setor que operam com volumes limitados de dados anotados, indicando quais combinações de técnicas como *transfer learning*, *data augmentation* e pré-processamento fotométrico produzem ganhos reais de desempenho nessa configuração específica (PAIANO

et al., 2024; SITU et al., 2023), sem depender de infraestrutura de coleta de dados em larga escala.

1.3 Objetivos

1.3.1 Objetivo Geral

Avaliar o desempenho de estratégias de treinamento em modelos de visão computacional aplicados à detecção de defeitos em cartas Pokémon TCG em cenários com baixo volume de dados.

1.3.2 Objetivos Específicos

1. Organizar e preparar um conjunto de dados de imagens de cartas Pokémon TCG, garantindo consistência nas anotações e nas condições de captura.
2. Implementar modelos de detecção de objetos baseados na arquitetura YOLO para identificação de defeitos visuais nas cartas.
3. Aplicar estratégias de treinamento voltadas a cenários com poucos dados, incluindo *transfer learning*, aumento de dados (*data augmentation*) e técnicas de pré-processamento de imagem.
4. Conduzir um estudo de ablação para analisar o impacto individual de cada estratégia de treinamento no desempenho dos modelos.
5. Comparar o desempenho das diferentes configurações por meio de métricas quantitativas, como precisão, *recall*, F1-score e *mean Average Precision* (mAP).
6. Analisar os resultados obtidos, identificando quais combinações de estratégias e modelos apresentam melhor desempenho em cenários com conjuntos de dados limitados.

2 Revisão Bibliográfica

A revisão bibliográfica tem como finalidade apresentar o embasamento teórico do trabalho, demonstrando o conhecimento do autor sobre o tema e identificando o estado da arte. Este capítulo deve ser organizado por conceitos e temas, construindo uma linha de argumentação que sustente a proposta do trabalho.

2.1 Referencial teórico

2.1.1 Trading Card Games e o Mercado de Colecionismo

Trading Card Games (TCGs) são jogos baseados em cartas colecionáveis, associados a franquias de entretenimento como Pokémon e Magic: The Gathering (NAHAR et al., 2025). Diferentemente de jogos de cartas tradicionais, cada carta em um TCG pode apresentar atributos próprios de arte, raridade e uso em jogo, o que lhe confere também valor de colecionismo individual. No caso do Pokémon TCG, essa combinação entre jogabilidade estratégica e cultura de colecionismo também se reflete na existência de um mercado secundário ativo para a compra e venda de cartas individuais (SHEN; WEI, 2025).

Nesse mercado, o valor comercial de uma carta está fortemente associado ao seu estado de conservação físico. Imperfeições como arranhões na superfície, desgaste nas bordas ou problemas de centralização podem reduzir de forma significativa o preço de mercado do item (NAHAR et al., 2025). Para padronizar essa avaliação e aumentar a confiabilidade das transações, consolidou-se a atuação de empresas especializadas em graduação de cartas (*card grading*), como a PSA (*Professional Sports Authenticator*) e a Beckett Grading Services (SHEN; WEI, 2025).

A PSA, fundada em 1991, teve papel pioneiro na padronização desse tipo de avaliação ao adotar uma escala de 10 pontos amplamente utilizada no setor, enquanto a Beckett, a partir de 1999, introduziu subnotas para atributos individuais da carta, ampliando o detalhamento do processo de graduação (SHEN; WEI, 2025). Esse modelo de avaliação padronizada tornou-se central no mercado secundário de cartas, pois permite autenticar, encapsular e classificar itens de forma mais confiável para compradores e vendedores (HECK et al., 2026).

O processo de graduação considera, em geral, quatro atributos físicos da carta: superfície (*surface*), bordas (*edges*), cantos (*corners*) e centralização (*centering*). A nota final, em uma escala de 1 a 10, resulta da análise combinada desses fatores (NAHAR et al., 2025). Cartas classificadas com notas mais altas, como *Gem Mint*, tendem a alcançar valores substancialmente superiores aos de exemplares com notas mais baixas, em razão da maior

preservação de suas características físicas (WARREN; PIMBBLETT; MBOLI, 2026; HECK et al., 2026).

2.1.2 Visão Computacional e Inspeção Visual Automatizada

Visão computacional é a área da ciência da computação que desenvolve métodos para que sistemas digitais interpretem e analisem imagens e vídeos automaticamente. Na indústria de manufatura, essa tecnologia é aplicada em sistemas de inspeção visual automatizada (*Automated Visual Inspection* – AVI), cuja função é substituir ou apoiar a inspeção manual de qualidade em linhas de produção (ZHENG et al., 2021).

Um sistema AVI é composto por três etapas principais: aquisição de imagem, detecção de defeitos e controle de qualidade. A etapa de aquisição utiliza câmeras digitais, combinadas com sistemas de iluminação controlada para garantir contraste adequado entre as características do produto e possíveis defeitos. A etapa de detecção aplica algoritmos de processamento de imagem para identificar e classificar anomalias. Por fim, os resultados são enviados ao sistema de controle de qualidade, que determina a aceitação ou rejeição do produto (ZHENG et al., 2021).

Os algoritmos tradicionais de AVI dependem de características projetadas manualmente por especialistas e tendem a ser sensíveis a variações nas condições de aplicação (ZHENG et al., 2021). Com o avanço do *Deep Learning*, uma nova geração de algoritmos passou a aprender padrões diretamente dos dados de treinamento. Redes Neurais Convolucionais (CNNs) tornaram-se a abordagem predominante nesse contexto (ZHENG et al., 2021).

Na prática industrial, sistemas baseados em CNNs têm sido aplicados com sucesso na inspeção de defeitos em semicondutores, aço e tecidos, atingindo taxas de acurácia superiores a 99% em alguns casos (ZHENG et al., 2021), consolidando o *Deep Learning* como abordagem predominante para inspeção visual automatizada.

2.1.3 Deep Learning e Redes Neurais Convolucionais

Deep Learning é uma subárea do aprendizado de máquina que utiliza redes neurais artificiais com múltiplas camadas para aprender representações de dados a partir de exemplos, sem necessidade de características projetadas manualmente (ZHENG et al., 2021). No contexto de visão computacional, as Redes Neurais Convolucionais (CNNs, do inglês *Convolutional Neural Networks*) são a arquitetura predominante para tarefas de classificação de imagens, detecção de objetos e inspeção de defeitos (HUSSAIN, 2023). As CNNs utilizam múltiplas camadas convolucionais combinadas com estruturas de agrupamento (*pooling*) para extrair padrões visuais diretamente dos pixels da imagem (HUSSAIN, 2023).

Na inspeção visual automatizada de produtos industriais, CNNs têm demonstrado resultados superiores aos métodos tradicionais na detecção de defeitos em superfícies

(ZHENG et al., 2021). Esse desempenho justifica sua adoção em contextos com desafios visuais similares, incluindo a graduação de cartas colecionáveis (WARREN; PIMBBLETT; MBOLI, 2026).

2.1.4 Desafios Técnicos na Inspeção de Cartas

A inspeção automatizada de cartas TCG apresenta desafios técnicos que a diferenciam da inspeção industrial convencional. O primeiro deles é a variação de iluminação durante a captura das imagens. Warren, Pimbblett e Mboli (2026) denominam esse fenômeno de *Shadow Problem*: inconsistências de brilho causadas pela geometria do equipamento de captura, pelo ângulo da câmera e por reflexos ambientais. Sem correção adequada, esses artefatos visuais degradam a qualidade da imagem e podem levar a classificações incorretas pelos modelos de graduação (WARREN; PIMBBLETT; MBOLI, 2026).

O segundo desafio são os reflexos em superfícies holográficas (*foil*). Cartas com impressão holográfica refletem luz de forma intensa e irregular, o que pode obscurecer defeitos críticos como arranhões e desgastes de superfície. Esse comportamento óptico dificulta a segmentação da imagem e compromete a precisão de modelos treinados em condições de iluminação uniforme (WARREN; PIMBBLETT; MBOLI, 2026). Para mitigar esse problema, Nahar et al. (2025) optaram por substituir câmeras convencionais por scanners de alta resolução, garantindo iluminação constante e padronizada durante a captura.

O terceiro desafio é a subjetividade inerente ao processo de avaliação manual. Como os quatro critérios de graduação, superfície, bordas, cantos e centralização, são analisados visualmente por avaliadores humanos, o resultado final tende a variar entre profissionais diferentes, especialmente em casos limítrofes (NAHAR et al., 2025). Esse fator limita a reprodutibilidade das avaliações e compromete a confiabilidade do processo em escala industrial (WARREN; PIMBBLETT; MBOLI, 2026).

Por fim, o cálculo preciso da centralização representa um desafio geométrico específico. As bordas de uma carta padrão TCG têm espessura de poucos milímetros, o que significa que variações mínimas na detecção dessas bordas já são suficientes para alterar a nota final do critério (WARREN; PIMBBLETT; MBOLI, 2026). Medir essas bordas com precisão exige algoritmos dedicados de detecção de bordas e tratamento prévio de ruídos visuais para garantir medições consistentes (WARREN; PIMBBLETT; MBOLI, 2026; TIAN; WEI, 2022).

2.2 Metodologia da pesquisa bibliográfica

A pesquisa bibliográfica foi realizada na base Google Scholar, utilizando combinações de termos em inglês diretamente relacionados aos temas centrais do trabalho. As principais expressões de busca utilizadas foram: *"transfer learning" AND "object detection" AND*

"small dataset" AND "performance evaluation", *"trading card" OR "collectible card" AND "computer vision"*, *"card grading" AND "automated" OR "machine learning"*, *"surface defect detection" AND "computer vision" AND "scratch" OR "wear"* e *"subpixel edge detection" AND "measurement precision" AND "computer vision"*.

Foram considerados apenas artigos científicos publicados entre 2021 e 2026, em língua inglesa, disponíveis em periódicos ou anais de conferências revisados por pares. Materiais como blogs, relatórios técnicos não revisados e trabalhos de conclusão de curso foram excluídos. A relevância de cada trabalho foi avaliada com base na aderência ao problema de pesquisa: detecção automatizada de defeitos visuais em cenários com baixo volume de dados, com ênfase em aplicações de visão computacional em domínios especializados.

2.3 Fundamentos

Aprofunde os conceitos técnicos que serão utilizados na solução proposta. Diferentemente do referencial teórico (que apresenta conceitos gerais), os fundamentos devem detalhar as tecnologias, algoritmos, frameworks ou metodologias específicas que serão empregados no desenvolvimento.

Por exemplo:

- Se o trabalho utiliza aprendizado de máquina, explique os algoritmos escolhidos (árvores de decisão, redes neurais, SVM, etc.);
- Se o trabalho envolve desenvolvimento de software, descreva as tecnologias (linguagens, frameworks, bancos de dados);
- Se envolve análise de dados, explique as métricas e técnicas estatísticas que serão aplicadas.

Utilize figuras, diagramas e tabelas para ilustrar conceitos quando apropriado.

2.4 Trabalhos relacionados

Apresente até **3 trabalhos** que **compartilhem o mesmo foco de resolução de problema** que o seu. O critério principal de seleção é: os trabalhos escolhidos devem ter tentado resolver o **mesmo problema** (ou um problema muito próximo) ao que você está propondo resolver. Não basta que o trabalho aborde o mesmo tema ou utilize a mesma tecnologia — ele deve ter enfrentado o mesmo desafio prático ou teórico.

Por que esse critério é importante? Ao selecionar trabalhos que atacam o mesmo problema, você demonstra que:

- O problema é relevante e já foi reconhecido por outros pesquisadores;

- Existem soluções anteriores, mas com limitações que o seu trabalho pretende superar;
- Seu trabalho não é uma repetição, mas um avanço em relação ao que já foi feito.

Para cada trabalho relacionado, descreva:

1. **Qual problema** o trabalho tentou resolver (e por que é o mesmo problema que o seu);
2. A metodologia ou abordagem utilizada para resolvê-lo;
3. Os principais resultados obtidos;
4. As limitações identificadas na solução proposta;
5. Como o **seu trabalho se diferencia** ou avança em relação a ele.

2.4.1 Trabalho 1: [Título do trabalho]

??) abordou o problema de [descrever o problema — deve ser o mesmo ou muito similar ao seu]. Para resolvê-lo, os autores propuseram [descrever a solução]. A metodologia utilizada foi [descrever]. Os resultados mostraram que [descrever]. No entanto, a solução apresenta limitações como [descrever as lacunas que permanecem]. O presente trabalho diferencia-se por [explicar como sua proposta avança na resolução do mesmo problema].

2.4.2 Trabalho 2: [Título do trabalho]

[Descrever o segundo trabalho seguindo a mesma estrutura acima, sempre evidenciando que o problema abordado é o mesmo ou muito próximo ao seu.]

2.4.3 Trabalho 3: [Título do trabalho]

[Descrever o terceiro trabalho seguindo a mesma estrutura acima, sempre evidenciando que o problema abordado é o mesmo ou muito próximo ao seu.]

Uma tabela comparativa ajuda a sintetizar as diferenças entre os trabalhos:

Tabela 1 – Comparação entre trabalhos relacionados

Critério	**Trabalho 1**	**Trabalho 2**	**Trabalho 3**	**Este trabalho**
Objetivo	[resumo]	[resumo]	[resumo]	[resumo]
Tecnologia	[tecn.]	[tecn.]	[tecn.]	[tecn.]
Validação	[método]	[método]	[método]	[método]
Limitação	[limit.]	[limit.]	[limit.]	—

Fonte: Elaborado pelo autor (2026)

3 Desenvolvimento

Neste capítulo, apresenta-se a solução proposta para o problema identificado, bem como o cronograma de trabalho previsto para o desenvolvimento completo do projeto no TCC2.

3.1 Solução proposta

Descreva detalhadamente a solução que será desenvolvida para resolver o problema apresentado na introdução. A descrição deve incluir:

- **Visão geral da solução**: o que será desenvolvido (sistema, aplicativo, modelo, ferramenta, etc.);
- **Arquitetura**: como os componentes da solução se organizam e interagem;
- **Tecnologias e ferramentas**: quais linguagens, frameworks, bibliotecas, bancos de dados e ambientes serão utilizados, e por que foram escolhidos;
- **Funcionalidades principais**: o que a solução fará para atender aos objetivos;
- **Metodologia de desenvolvimento**: qual abordagem será utilizada (ágil, cascata, prototipação, etc.);
- **Critérios de validação**: como será medido o sucesso da solução (métricas, testes, avaliação com usuários, etc.).

Utilize diagramas, fluxogramas ou mockups para ilustrar a solução. Exemplo de descrição de arquitetura:

A solução proposta consiste em uma aplicação web composta por três camadas: front-end desenvolvido em React.js, back-end em Node.js com Express, e banco de dados PostgreSQL. A comunicação entre front-end e back-end será feita por meio de uma API REST.

3.2 Cronograma de trabalho

O cronograma a seguir apresenta, no formato de diagrama de Gantt, as atividades previstas para o desenvolvimento do TCC2, distribuídas ao longo das semanas do semestre.

Instruções para personalização do cronograma:

- Ajuste o número de semanas conforme o calendário acadêmico do semestre;
- Modifique as atividades de acordo com as etapas do seu projeto;

Figura 1 – Cronograma de atividades – Diagrama de Gantt

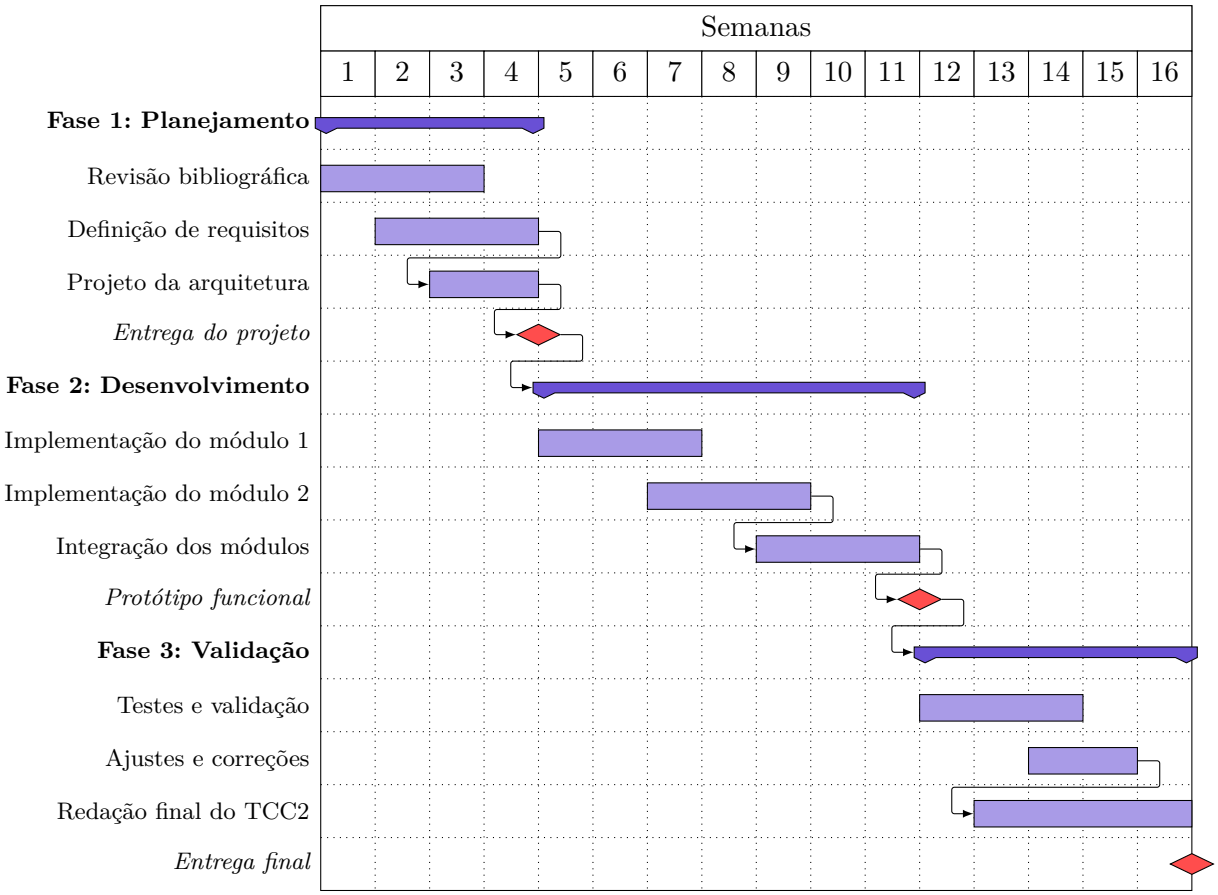

Fonte: Elaborado pelo autor (2026)

- Os marcos (*milestones*) indicam entregas importantes — adapte-os às datas de avaliação;
- As setas entre atividades indicam dependências — uma atividade só inicia após a conclusão da anterior;
- Utilize o diagrama como ferramenta de acompanhamento: atualize-o a cada reunião com o orientador.

Referências

Business Research Insights. *Collectible Card Game Market Size, Share, Growth, Trends, Global Industry Analysis*. 2026. Acesso em: 15 mar. 2026. Disponível em: <https://www.businessresearchinsights.com/market-reports/collectible-card-game-market-101837>. 4

HECK, J. et al. Sales characteristics of pokémon trading cards: A prospective one-year field study. *PLOS One*, v. 21, n. 3, p. 334289, 2026. 8, 9

HUSSAIN, M. YOLO-v1 to YOLO-v8, the rise of YOLO and its complementary nature toward digital manufacturing and industrial defect detection. *Machines*, v. 11, n. 7, p. 677, 2023. 9

NAHAR, L. et al. Automated corner grading of trading cards: Defect identification and confidence calibration through deep learning. *Computers in Industry*, v. 164, p. 104187, 2025. 4, 5, 6, 8, 10

PAIANO, M. et al. Transfer learning with generative models for object detection on limited datasets. *Machine Learning: Science and Technology*, v. 5, n. 3, p. 035041, 2024. 5, 6, 7

SHEN, Q.; WEI, C. Business model innovation in the trading card grading industry: Cross-national insights from pokémon trading card game and non-fungible tokens. *Asian Journal of Business and Strategic Perspectives*, v. 2, n. 2, 2025. Disponível em: <https://doi.org/10.70122/ajbsp.v2i2.37>. 4, 8

SITU, Z. et al. A transfer learning-based yolo network for sewer defect detection in comparison to classic object detection methods. *Developments in the Built Environment*, v. 15, p. 100191, 2023. 5, 6, 7

TIAN, B.; WEI, W. Research overview on edge detection algorithms based on deep learning and image fusion. *Security and Communication Networks*, p. 1155814, 2022. 4, 6, 10

WARREN, L.; PIMBBLETT, K.; MBOLI, J. TCG-AI: AI integration in collectibles grading for trading card games and sport cards. *Research Square*, 2026. Preprint. 4, 5, 6, 9, 10

ZHENG, X. et al. Recent advances in surface defect inspection of industrial products using deep learning techniques. *The International Journal of Advanced Manufacturing Technology*, 2021. 4, 6, 9, 10