Matheus da Silva Marini – Matrícula: 1142514833

AVALIAÇÃO DE DESEMPENHO DE ALGORITMOS DE VISÃO COMPUTACIONAL NO SUPORTE À GRADUAÇÃO DE CARTAS POKÉMON TCG

São Paulo

2026

Matheus da Silva Marini – Matrícula: 1142514833

AVALIAÇÃO DE DESEMPENHO DE ALGORITMOS DE VISÃO COMPUTACIONAL NO SUPORTE À GRADUAÇÃO DE CARTAS POKÉMON TCG

Proposta de Trabalho de Conclusão de Curso apresentado ao SENAC Santo Amaro como requisito parcial para aprovação na disciplina de TCC1 do curso de Ciência da Computação.

SENAC – Serviço Nacional de Aprendizagem Comercial
Unidade Santo Amaro
Curso de Ciência da Computação

Orientador: Prof. Afonso Lelis

São Paulo
2026

Resumo

Este documento apresenta a proposta inicial do Trabalho de Conclusão de Curso (TCC1) desenvolvido no SENAC Santo Amaro. O objetivo deste trabalho é avaliar o desempenho de algoritmos de visão computacional no suporte à graduação de cartas Pokémon TCG, com foco na redução do tempo de inspeção. A justificativa para este estudo baseia-se na necessidade de resolver um problema real de lentidão e subjetividade na graduação de cartas por meio de um artefato computacional. A revisão bibliográfica abrange visão computacional, deep learning e automação de processos. Como solução proposta, pretende-se implementar algoritmos geométricos e redes neurais para apoiar a decisão humana. Este trabalho está organizado em três capítulos que apresentam a introdução ao tema, a revisão bibliográfica que fundamenta a pesquisa, o desenvolvimento com a solução proposta e o cronograma de trabalho, seguidos das referências bibliográficas.

Palavras-chave: Visão Computacional. Deep Learning. YOLOv8. Pokémon TCG. Design Science Research.

Sumário

1 INTRODUÇÃO . . . 4
1.1 Contexto . . . 5
1.2 Justificativa . . . 6
1.3 Objetivos . . . 6
1.3.1 Objetivo Geral . . . 6
1.3.2 Objetivos Específicos . . . 6
1.4 Metodologia Escolhida . . . 7
1.5 Hipótese de Pesquisa . . . 7
1.6 Métricas de Avaliação . . . 7

2 REVISÃO BIBLIOGRÁFICA . . . 8
2.1 Referencial teórico . . . 8
2.1.1 Trading Card Games e o Mercado de Colecionismo . . . 8
2.1.2 Visão Computacional e Inspeção Visual Automatizada . . . 9
2.1.3 Desafios Técnicos na Inspeção de Cartas . . . 9
2.1.4 Deep Learning e Redes Neurais Convolucionais . . . 10
2.2 Metodologia da pesquisa bibliográfica . . . 10
2.3 Fundamentos . . . 11
2.4 Trabalhos relacionados . . . 11
2.4.1 Trabalho 1: [Título do trabalho] . . . 12
2.4.2 Trabalho 2: [Título do trabalho] . . . 12
2.4.3 Trabalho 3: [Título do trabalho] . . . 12

3 DESENVOLVIMENTO . . . 14
3.1 Solução proposta . . . 14
3.2 Cronograma de trabalho . . . 14

REFERÊNCIAS . . . 16

1 Introdução

O mercado de Trading Card Games (TCG), representado por franquias como Pokémon e Magic: The Gathering, segundo projeções do setor, deve movimentar aproximadamente 20 bilhões de dólares globalmente em 2026, com projeção de ultrapassar 76 bilhões até 2035 (Business Research Insights, 2026). Nesse mercado, o valor de uma carta está diretamente ligado ao seu estado de conservação (NAHAR et al., 2025). Para certificar essa condição e garantir a segurança das transações, consolidou-se o serviço especializado de graduação de cartas (*grading*). A PSA, fundada em 1991, foi a pioneira em padronizar essa avaliação ao estabelecer uma escala de 10 pontos que se tornaria norma do setor, enquanto a Beckett, em 1999, introduziu subnotas para atributos individuais (SHEN; WEI, 2025). Essa metodologia baseia-se na inspeção de quatro atributos físicos: superfície (*surface*), bordas (*edges*), cantos (*corners*) e centralização (*centering*), sendo a nota final definida pela análise combinada desses fatores (NAHAR et al., 2025).

O processo de graduação, no entanto, ainda é realizado de forma predominantemente manual. Os avaliadores inspecionam cada carta com lupas e iluminação controlada, o que torna a análise demorada e sujeita à subjetividade de cada profissional (NAHAR et al., 2025). Isso limita a capacidade das empresas de escalar o serviço, gerando longas filas de espera para os consumidores. Além disso, o manuseio frequente durante a inspeção representa um risco à carta em si, pois o contato repetido pode causar desgastes que reduzem diretamente a nota do item avaliado (NAHAR et al., 2025). Num mercado onde pequenas diferenças de conservação representam grandes variações de preço, essa inconsistência tem consequências financeiras diretas (NAHAR et al., 2025; WARREN; PIMBBLETT; MBOLI, 2026).

Diante dessas limitações, a automação tecnológica tem sido investigada como alternativa à inspeção manual. Na indústria de manufatura, sistemas de visão computacional já são utilizados para automatizar inspeções de qualidade, usando arquiteturas de *Deep Learning* e Redes Neurais Convolucionais (CNNs) para detectar defeitos em tempo real (ZHENG et al., 2021). No entanto, adaptar essas abordagens para cartas colecionáveis apresenta desafios específicos. Variações de iluminação e reflexos em superfícies holográficas (*foil*) podem obscurecer defeitos críticos e comprometer a precisão dos modelos (WARREN; PIMBBLETT; MBOLI, 2026). Além disso, o cálculo da centralização depende da detecção precisa das bordas da carta, o que exige tratamento prévio de ruídos visuais para garantir medições consistentes (WARREN; PIMBBLETT; MBOLI, 2026; TIAN; WEI, 2022).

Pesquisadores já investigaram o uso dessas técnicas no contexto específico da graduação de cartas colecionáveis (WARREN; PIMBBLETT; MBOLI, 2026; NAHAR et al., 2025), mas as abordagens existentes apresentam escopo limitado ou carecem de validação sistemática que compare diferentes arquiteturas nesse domínio. Diante disso, este trabalho

propõe um sistema de pré-avaliação automatizada. A arquitetura combina o OpenCV para o cálculo da centralização (WARREN; PIMBBLETT; MBOLI, 2026) com o modelo de detecção de objetos YOLOv8 para localizar e classificar danos de superfície (HUSSAIN, 2023; YUE et al., 2025). O objetivo não é substituir o avaliador humano, mas oferecer uma ferramenta que organize as informações antes da inspeção final, reduzindo a subjetividade e o tempo gasto por carta.

1.1 Contexto

O ecossistema brasileiro de cartas colecionáveis tem demonstrado sinais claros de aquecimento, impulsionado principalmente pela alta rotatividade no mercado secundário. Como indicador dessa tendência, plataformas de revenda entre consumidores registraram aumentos expressivos no volume de transações; levantamentos recentes apontam um crescimento de 130% nas negociações de cartas da franquia Pokémon em plataformas como a OLX apenas no ano de 2025 (IGN Brasil, 2025). Esse volume intenso de vendas de cartas reforça a demanda por serviços de autenticação e graduação de estado de conservação no país. Nesse cenário, empresas especializadas em graduação de cartas têm surgido no Brasil para atender à demanda por avaliações padronizadas, como a Capy Games, graduadora brasileira que oferece serviços de avaliação de estado de conservação de cartas TCG (Capy Games, 2026).

O processo de graduação realizado por essas empresas é conduzido manualmente, com avaliadores inspecionando cada carta de forma individual. Esse modelo apresenta um gargalo operacional claro: a capacidade de processamento é limitada pelo tempo e pela disponibilidade de avaliadores humanos. A própria Capy Games, por exemplo, exibe seu serviço principal de graduação como indisponível em razão de alta demanda, com previsão de retorno de envios em breve (Capy Games, 2026). Esse cenário ilustra diretamente o problema que este trabalho pretende endereçar: a dificuldade de escalar o processo de graduação sem comprometer a qualidade das avaliações.

Além do volume, o processo manual introduz variabilidade nos resultados. A análise visual de atributos como centralização, estado de bordas e cantos depende da percepção subjetiva de cada avaliador, o que pode gerar inconsistências entre avaliações de uma mesma carta realizadas por profissionais diferentes (NAHAR et al., 2025; WARREN; PIMBBLETT; MBOLI, 2026). Em um mercado onde frações de nota representam diferenças significativas de valor financeiro, essa variabilidade é um problema real para compradores, vendedores e para a credibilidade das próprias graduadoras.

1.2 Justificativa

Este trabalho se justifica pela necessidade de desenvolver uma ferramenta computacional que reduza os dois principais problemas identificados no processo atual de graduação de cartas TCG: o tempo de avaliação e a subjetividade do resultado.

Do ponto de vista técnico, a proposta é viável porque algoritmos de visão computacional já demonstraram capacidade de detectar defeitos superficiais em produtos industriais com alta precisão (ZHENG et al., 2021). A adaptação dessas técnicas para o domínio específico das cartas colecionáveis representa uma contribuição original, dado que os desafios visuais desse domínio, como reflexos holográficos e bordas de poucos milímetros, ainda carecem de soluções consolidadas (WARREN; PIMBBLETT; MBOLI, 2026).

Do ponto de vista prático, a ferramenta proposta não substitui o avaliador humano, mas atua como um sistema de pré-avaliação que organiza e quantifica as informações antes da inspeção final. Isso tem potencial de reduzir o tempo médio por carta e aumentar a consistência entre avaliações, beneficiando diretamente empresas como a Capy Games que enfrentam filas de espera por limitações de capacidade operacional (Capy Games, 2026). A abordagem experimental adotada, testando e comparando diferentes algoritmos por meio de métricas quantitativas, permite validar qual arquitetura oferece a melhor relação entre precisão e velocidade de inferência, produzindo resultados reproduzíveis e auditáveis (NAHAR et al., 2025).

1.3 Objetivos

1.3.1 Objetivo Geral

Avaliar o desempenho de algoritmos de visão computacional no suporte à graduação de cartas Pokémon TCG, com foco na redução do tempo de inspeção.

1.3.2 Objetivos Específicos

1. Pré-processar e estruturar um *dataset* de imagens de cartas Pokémon, aplicando técnicas para padronização de iluminação e mitigação de reflexos especulares (holográficos).

2. Implementar algoritmos de visão computacional de diferentes categorias para o cálculo de centralização e modelos de *Deep Learning* para detecção de arranhões e desgastes.

3. Comparar o desempenho das abordagens implementadas através de métricas estatísticas e de custo computacional.

4. Propor uma interface de suporte à decisão que integre as detecções dos algoritmos e recomende uma pré-nota, visando agilizar o veredito final do avaliador humano.

1.4 Metodologia Escolhida

A metodologia adotada é a *Design Science Research* (DSR) para a construção do artefato computacional, com avaliação conduzida por meio de pesquisa experimental quantitativa aplicada. Essa abordagem permitirá medir e comparar o desempenho empírico (tempo de inferência e acurácia) entre os diferentes algoritmos propostos.

1.5 Hipótese de Pesquisa

O uso do sistema de suporte à decisão reduz o tempo médio de inspeção por carta em pelo menos 40% em comparação à avaliação manual sem suporte, mantendo desempenho de detecção de defeitos com *F1-score* ou $mAP \geq 0{,}90$.

1.6 Métricas de Avaliação

As métricas utilizadas para avaliar o desempenho e a viabilidade da solução proposta serão:

- **Erro de centralização**: MAE (erro absoluto médio) das margens estimadas vs referência (em pixels ou %), e % de casos dentro de um limiar de tolerância.
- **Precisão (*Precision*) e Revocação (*Recall*):** Para medir a exatidão e a sensibilidade na detecção de danos.
- **F1-Score / mAP (*Mean Average Precision*):** Para comparar o saldo geral de acertos entre os algoritmos testados.
- **Tempo de Inferência:** Medido em milissegundos (ms), para avaliar o custo computacional de cada modelo.
- **Redução Percentual de Tempo:** Comparação do tempo médio gasto por um humano avaliando uma carta do zero *versus* avaliando a carta com o suporte prévio do sistema.

2 Revisão Bibliográfica

A revisão bibliográfica tem como finalidade apresentar o embasamento teórico do trabalho, demonstrando o conhecimento do autor sobre o tema e identificando o estado da arte. Este capítulo deve ser organizado por conceitos e temas, construindo uma linha de argumentação que sustente a proposta do trabalho.

2.1 Referencial teórico

2.1.1 Trading Card Games e o Mercado de Colecionismo

Trading Card Games (TCGs) são jogos baseados em cartas colecionáveis, associados a franquias de entretenimento como Pokémon e Magic: The Gathering (NAHAR et al., 2025). Diferentemente de jogos de cartas tradicionais, cada carta em um TCG pode apresentar atributos próprios de arte, raridade e uso em jogo, o que lhe confere também valor de colecionismo individual. No caso do Pokémon TCG, essa combinação entre jogabilidade estratégica e cultura de colecionismo também se reflete na existência de um mercado secundário ativo para a compra e venda de cartas individuais (SHEN; WEI, 2025).

Nesse mercado, o valor comercial de uma carta está fortemente associado ao seu estado de conservação físico. Imperfeições como arranhões na superfície, desgaste nas bordas ou problemas de centralização podem reduzir de forma significativa o preço de mercado do item (NAHAR et al., 2025). Para padronizar essa avaliação e aumentar a confiabilidade das transações, consolidou-se a atuação de empresas especializadas em graduação de cartas (*card grading*), como a PSA (*Professional Sports Authenticator*) e a Beckett Grading Services (SHEN; WEI, 2025).

A PSA, fundada em 1991, teve papel pioneiro na padronização desse tipo de avaliação ao adotar uma escala de 10 pontos amplamente utilizada no setor, enquanto a Beckett, a partir de 1999, introduziu subnotas para atributos individuais da carta, ampliando o detalhamento do processo de graduação (SHEN; WEI, 2025). Esse modelo de avaliação padronizada tornou-se central no mercado secundário de cartas, pois permite autenticar, encapsular e classificar itens de forma mais confiável para compradores e vendedores (HECK et al., 2026).

O processo de graduação considera, em geral, quatro atributos físicos da carta: superfície (*surface*), bordas (*edges*), cantos (*corners*) e centralização (*centering*). A nota final, em uma escala de 1 a 10, resulta da análise combinada desses fatores (NAHAR et al., 2025). Cartas classificadas com notas mais altas, como *Gem Mint*, tendem a alcançar valores substancialmente superiores aos de exemplares com notas mais baixas, em razão da maior

preservação de suas características físicas (WARREN; PIMBBLETT; MBOLI, 2026; HECK et al., 2026).

2.1.2 Visão Computacional e Inspeção Visual Automatizada

Visão computacional é a área da ciência da computação que desenvolve métodos para que sistemas digitais interpretem e analisem imagens e vídeos automaticamente. Na indústria de manufatura, essa tecnologia é aplicada em sistemas de inspeção visual automatizada (*Automated Visual Inspection* – AVI), cuja função é substituir ou apoiar a inspeção manual de qualidade em linhas de produção (ZHENG et al., 2021).

Um sistema AVI é composto por três etapas principais: aquisição de imagem, detecção de defeitos e controle de qualidade. A etapa de aquisição utiliza câmeras digitais, combinadas com sistemas de iluminação controlada para garantir contraste adequado entre as características do produto e possíveis defeitos. A etapa de detecção aplica algoritmos de processamento de imagem para identificar e classificar anomalias. Por fim, os resultados são enviados ao sistema de controle de qualidade, que determina a aceitação ou rejeição do produto (ZHENG et al., 2021).

Os algoritmos tradicionais de AVI dependem de características projetadas manualmente por especialistas e tendem a ser sensíveis a variações nas condições de aplicação (ZHENG et al., 2021). Com o avanço do *Deep Learning*, uma nova geração de algoritmos passou a aprender padrões diretamente dos dados de treinamento. Redes Neurais Convolucionais (CNNs) tornaram-se a abordagem predominante nesse contexto (ZHENG et al., 2021).

Na prática industrial, sistemas baseados em CNNs têm sido aplicados com sucesso na inspeção de defeitos em semicondutores, aço e tecidos, atingindo taxas de acurácia superiores a 99% em alguns casos (ZHENG et al., 2021), o que motiva sua investigação em outros domínios com desafios similares de inspeção visual, como a graduação de cartas colecionáveis abordada neste trabalho.

2.1.3 Desafios Técnicos na Inspeção de Cartas

A inspeção automatizada de cartas TCG apresenta desafios técnicos que a diferenciam da inspeção industrial convencional. O primeiro deles é a variação de iluminação durante a captura das imagens. Warren, Pimbblett e Mboli (2026) denominam esse fenômeno de *Shadow Problem*: inconsistências de brilho causadas pela geometria do equipamento de captura, pelo ângulo da câmera e por reflexos ambientais. Sem correção adequada, esses artefatos visuais degradam a qualidade da imagem e podem levar a classificações incorretas pelos modelos de graduação (WARREN; PIMBBLETT; MBOLI, 2026).

O segundo desafio são os reflexos em superfícies holográficas (*foil*). Cartas com impressão holográfica refletem luz de forma intensa e irregular, o que pode obscurecer defeitos críticos como arranhões e desgastes de superfície. Esse comportamento óptico dificulta

a segmentação da imagem e compromete a precisão de modelos treinados em condições de iluminação uniforme (WARREN; PIMBBLETT; MBOLI, 2026). Para mitigar esse problema, Nahar et al. (2025) optaram por substituir câmeras convencionais por scanners de alta resolução, garantindo iluminação constante e padronizada durante a captura.

O terceiro desafio é a subjetividade inerente ao processo de avaliação manual. Como os quatro critérios de graduação — superfície, bordas, cantos e centralização — são analisados visualmente por avaliadores humanos, o resultado final tende a variar entre profissionais diferentes, especialmente em casos limítrofes (NAHAR et al., 2025). Esse fator limita a reprodutibilidade das avaliações e compromete a confiabilidade do processo em escala industrial (WARREN; PIMBBLETT; MBOLI, 2026).

Por fim, o cálculo preciso da centralização representa um desafio geométrico específico. As bordas de uma carta padrão TCG têm espessura de poucos milímetros, o que significa que variações mínimas na detecção dessas bordas já são suficientes para alterar a nota final do critério (WARREN; PIMBBLETT; MBOLI, 2026). Medir essas bordas com precisão exige algoritmos dedicados de detecção de bordas e tratamento prévio de ruídos visuais para garantir medições consistentes (WARREN; PIMBBLETT; MBOLI, 2026; TIAN; WEI, 2022).

2.1.4 Deep Learning e Redes Neurais Convolucionais

Deep Learning é uma subárea do aprendizado de máquina que utiliza redes neurais artificiais com múltiplas camadas para aprender representações de dados a partir de exemplos, sem necessidade de características projetadas manualmente (ZHENG et al., 2021). No contexto de visão computacional, as Redes Neurais Convolucionais (CNNs, do inglês *Convolutional Neural Networks*) são a arquitetura predominante para tarefas de classificação de imagens, detecção de objetos e inspeção de defeitos (HUSSAIN, 2023). As CNNs utilizam múltiplas camadas convolucionais combinadas com estruturas de agrupamento (*pooling*) para extrair padrões visuais diretamente dos pixels da imagem (HUSSAIN, 2023).

Na inspeção visual automatizada de produtos industriais, CNNs têm demonstrado resultados superiores aos métodos tradicionais na detecção de defeitos em superfícies (ZHENG et al., 2021). Esse desempenho justifica sua adoção em contextos com desafios visuais similares, incluindo a graduação de cartas colecionáveis (WARREN; PIMBBLETT; MBOLI, 2026).

2.2 Metodologia da pesquisa bibliográfica

Descreva como a pesquisa bibliográfica foi conduzida, incluindo:

- **Bases de dados consultadas**: Google Scholar, IEEE Xplore, ACM Digital Library, SciELO, Periódicos CAPES, entre outras;
- **Palavras-chave utilizadas**: liste os termos de busca em português e inglês;
- **Critérios de inclusão e exclusão**: quais critérios foram usados para selecionar ou descartar trabalhos (período, idioma, relevância, tipo de publicação);
- **Período de abrangência**: intervalo de anos das publicações consultadas.

Exemplo de descrição:

A pesquisa bibliográfica foi realizada nas bases Google Scholar, IEEE Xplore e ACM Digital Library, utilizando as palavras-chave "machine learning", "classificação de texto" e "processamento de linguagem natural". Foram selecionados artigos publicados entre 2018 e 2025, em português e inglês, que abordassem diretamente técnicas de classificação automática de documentos.

2.3 Fundamentos

Aprofunde os conceitos técnicos que serão utilizados na solução proposta. Diferentemente do referencial teórico (que apresenta conceitos gerais), os fundamentos devem detalhar as tecnologias, algoritmos, frameworks ou metodologias específicas que serão empregados no desenvolvimento.

Por exemplo:

- Se o trabalho utiliza aprendizado de máquina, explique os algoritmos escolhidos (árvores de decisão, redes neurais, SVM, etc.);
- Se o trabalho envolve desenvolvimento de software, descreva as tecnologias (linguagens, frameworks, bancos de dados);
- Se envolve análise de dados, explique as métricas e técnicas estatísticas que serão aplicadas.

Utilize figuras, diagramas e tabelas para ilustrar conceitos quando apropriado.

2.4 Trabalhos relacionados

Apresente até **3 trabalhos** que **compartilhem o mesmo foco de resolução de problema** que o seu. O critério principal de seleção é: os trabalhos escolhidos devem ter tentado resolver o **mesmo problema** (ou um problema muito próximo) ao que você está propondo resolver. Não basta que o trabalho aborde o mesmo tema ou utilize a mesma tecnologia — ele deve ter enfrentado o mesmo desafio prático ou teórico.

Por que esse critério é importante? Ao selecionar trabalhos que atacam o mesmo problema, você demonstra que:

- O problema é relevante e já foi reconhecido por outros pesquisadores;
- Existem soluções anteriores, mas com limitações que o seu trabalho pretende superar;
- Seu trabalho não é uma repetição, mas um avanço em relação ao que já foi feito.

Para cada trabalho relacionado, descreva:

1. **Qual problema** o trabalho tentou resolver (e por que é o mesmo problema que o seu);
2. A metodologia ou abordagem utilizada para resolvê-lo;
3. Os principais resultados obtidos;
4. As limitações identificadas na solução proposta;
5. Como o **seu trabalho se diferencia** ou avança em relação a ele.

2.4.1 Trabalho 1: [Título do trabalho]

??) abordou o problema de [descrever o problema — deve ser o mesmo ou muito similar ao seu]. Para resolvê-lo, os autores propuseram [descrever a solução]. A metodologia utilizada foi [descrever]. Os resultados mostraram que [descrever]. No entanto, a solução apresenta limitações como [descrever as lacunas que permanecem]. O presente trabalho diferencia-se por [explicar como sua proposta avança na resolução do mesmo problema].

2.4.2 Trabalho 2: [Título do trabalho]

[Descrever o segundo trabalho seguindo a mesma estrutura acima, sempre evidenciando que o problema abordado é o mesmo ou muito próximo ao seu.]

2.4.3 Trabalho 3: [Título do trabalho]

[Descrever o terceiro trabalho seguindo a mesma estrutura acima, sempre evidenciando que o problema abordado é o mesmo ou muito próximo ao seu.]

Uma tabela comparativa ajuda a sintetizar as diferenças entre os trabalhos:

Tabela 1 – Comparação entre trabalhos relacionados

Critério	**Trabalho 1**	**Trabalho 2**	**Trabalho 3**	**Este trabalho**
Objetivo	[resumo]	[resumo]	[resumo]	[resumo]
Tecnologia	[tecn.]	[tecn.]	[tecn.]	[tecn.]
Validação	[método]	[método]	[método]	[método]
Limitação	[limit.]	[limit.]	[limit.]	—

Fonte: Elaborado pelo autor (2026)

3 Desenvolvimento

Neste capítulo, apresenta-se a solução proposta para o problema identificado, bem como o cronograma de trabalho previsto para o desenvolvimento completo do projeto no TCC2.

3.1 Solução proposta

Descreva detalhadamente a solução que será desenvolvida para resolver o problema apresentado na introdução. A descrição deve incluir:

- **Visão geral da solução**: o que será desenvolvido (sistema, aplicativo, modelo, ferramenta, etc.);
- **Arquitetura**: como os componentes da solução se organizam e interagem;
- **Tecnologias e ferramentas**: quais linguagens, frameworks, bibliotecas, bancos de dados e ambientes serão utilizados, e por que foram escolhidos;
- **Funcionalidades principais**: o que a solução fará para atender aos objetivos;
- **Metodologia de desenvolvimento**: qual abordagem será utilizada (ágil, cascata, prototipação, etc.);
- **Critérios de validação**: como será medido o sucesso da solução (métricas, testes, avaliação com usuários, etc.).

Utilize diagramas, fluxogramas ou mockups para ilustrar a solução. Exemplo de descrição de arquitetura:

A solução proposta consiste em uma aplicação web composta por três camadas: front-end desenvolvido em React.js, back-end em Node.js com Express, e banco de dados PostgreSQL. A comunicação entre front-end e back-end será feita por meio de uma API REST.

3.2 Cronograma de trabalho

O cronograma a seguir apresenta, no formato de diagrama de Gantt, as atividades previstas para o desenvolvimento do TCC2, distribuídas ao longo das semanas do semestre.

Instruções para personalização do cronograma:

- Ajuste o número de semanas conforme o calendário acadêmico do semestre;
- Modifique as atividades de acordo com as etapas do seu projeto;

Figura 1 – Cronograma de atividades – Diagrama de Gantt

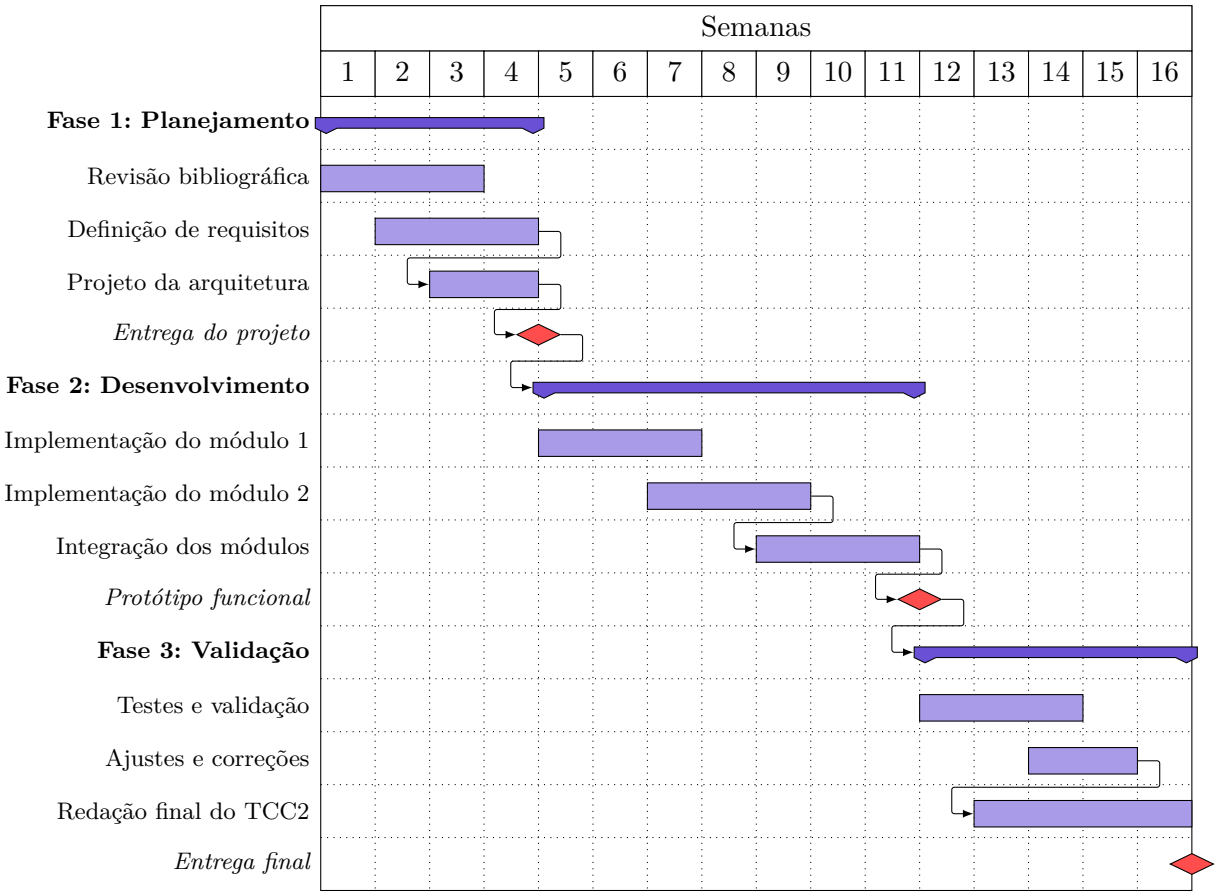

Fonte: Elaborado pelo autor (2026)

- Os marcos (*milestones*) indicam entregas importantes — adapte-os às datas de avaliação;
- As setas entre atividades indicam dependências — uma atividade só inicia após a conclusão da anterior;
- Utilize o diagrama como ferramenta de acompanhamento: atualize-o a cada reunião com o orientador.

Referências

Business Research Insights. *Collectible Card Game Market Size, Share, Growth, Trends, Global Industry Analysis*. 2026. Acesso em: 15 mar. 2026. Disponível em: <https://www.businessresearchinsights.com/market-reports/collectible-card-game-market-101837>. 4

Capy Games. *Preços e Serviços – Grading TCG*. 2026. Acesso em: 15 mar. 2026. Disponível em: <https://grading.capygames.com.br/preos-e-servios>. 5, 6

HECK, J. et al. Sales characteristics of pokémon trading cards: A prospective one-year field study. *PLOS One*, v. 21, n. 3, p. 334289, 2026. 8, 9

HUSSAIN, M. YOLO-v1 to YOLO-v8, the rise of YOLO and its complementary nature toward digital manufacturing and industrial defect detection. *Machines*, v. 11, n. 7, p. 677, 2023. 5, 10

IGN Brasil. *Febre de TCG: vendas de cartas Pokémon na OLX tiveram crescimento de 130% neste ano*. 2025. Acesso em: 15 mar. 2026. Disponível em: <https://br.ign.com/pokemon/147731/news/febre-de-tcg-vendas-de-cartas-pokemon-na-olx-tiveram-crescimento-de-130-neste-ano>. 5

NAHAR, L. et al. Automated corner grading of trading cards: Defect identification and confidence calibration through deep learning. *Computers in Industry*, v. 164, p. 104187, 2025. 4, 5, 6, 8, 10

SHEN, Q.; WEI, C. Business model innovation in the trading card grading industry: Cross-national insights from pokémon trading card game and non-fungible tokens. *Asian Journal of Business and Strategic Perspectives*, v. 2, n. 2, 2025. Disponível em: <https://doi.org/10.70122/ajbsp.v2i2.37>. 4, 8

TIAN, B.; WEI, W. Research overview on edge detection algorithms based on deep learning and image fusion. *Security and Communication Networks*, p. 1155814, 2022. 4, 10

WARREN, L.; PIMBBLETT, K.; MBOLI, J. TCG-AI: AI integration in collectibles grading for trading card games and sport cards. *Research Square*, 2026. Preprint. 4, 5, 6, 9, 10

YUE, Z. et al. Real-time steel surface defect detection using YOLOv8 and OpenCV: Enhancing accuracy and efficiency in industrial applications. In: *2025 International Conference on Metaverse and Current Trends in Computing (ICMCTC)*. Subang Jaya, Malaysia: [s.n.], 2025. 5

ZHENG, X. et al. Recent advances in surface defect inspection of industrial products using deep learning techniques. *The International Journal of Advanced Manufacturing Technology*, 2021. 4, 6, 9, 10