

Matheus da Silva Marini – Matrícula: 1142514833

**Avaliação de técnicas de visão computacional
para detecção de defeitos em cartas Pokémon
TCG em cenários com baixo volume de dados
aplicada à graduação de cartas**

São Paulo

2026

Matheus da Silva Marini – Matrícula: 1142514833

**Avaliação de técnicas de visão computacional para
detecção de defeitos em cartas Pokémon TCG em
cenários com baixo volume de dados aplicada à graduação
de cartas**

Proposta de Trabalho de Conclusão de Curso
apresentada ao SENAC Santo Amaro como
requisito parcial para aprovação na disciplina
de TCC1 do curso de Ciência da Computação.

SENAC – Serviço Nacional de Aprendizagem Comercial
Unidade Santo Amaro
Curso de Ciência da Computação

Orientador: Prof. Afonso Lelis

São Paulo
2026

Resumo

Este documento apresenta a proposta inicial do Trabalho de Conclusão de Curso (TCC1) desenvolvido no SENAC Santo Amaro. O objetivo deste trabalho é comparar estratégias de visão computacional aplicadas à detecção de defeitos superficiais em cartas Pokémon TCG em cenários de baixo volume de dados, identificando quais abordagens apresentam melhor desempenho com conjuntos limitados de imagens anotadas. A justificativa baseia-se na escassez de bases de dados públicas anotadas por especialistas e no alto custo de rotulagem, o que limita o treinamento de modelos tradicionais e motiva o uso de técnicas específicas para poucos exemplos (*small dataset*). Como contexto de aplicação, destaca-se o processo de graduação de cartas, atualmente realizado de forma manual e sujeito à subjetividade. A revisão bibliográfica abrange visão computacional, inspeção visual automatizada, Deep Learning, *transfer learning* e técnicas para treinamento com conjuntos limitados de imagens anotadas. Como solução proposta, pretende-se implementar um pipeline de treinamento e avaliação utilizando o modelo YOLOv8, combinado com técnicas de fotometria e aumento de dados (*data augmentation*), comparando o impacto de diferentes estratégias de treinamento por meio de métricas quantitativas em um *dataset* real de 88 cartas fornecido por uma empresa brasileira especializada em graduação de cartas TCG.

Palavras-chave: Visão Computacional. Detecção de Defeitos. Pokémon TCG. Small Datasets. YOLOv8.

Sumário

1	INTRODUÇÃO	5
1.1	Contexto	6
1.2	Justificativa	7
1.3	Objetivos	8
1.3.1	Objetivo Geral	8
1.3.2	Objetivos Específicos	8
2	REVISÃO BIBLIOGRÁFICA	9
2.1	Referencial teórico	9
2.1.1	Deep Learning e Redes Neurais Convolucionais	9
2.1.2	Visão Computacional e Inspeção Visual Automatizada	9
2.1.3	Trading Card Games e o Mercado de Colecionismo	10
2.1.4	Desafios Técnicos na Inspeção de Cartas	11
2.2	Metodologia da pesquisa bibliográfica	11
2.3	Fundamentos	12
2.3.1	Detecção de Objetos	12
2.3.2	Arquitetura YOLO	13
2.3.3	Transfer Learning	14
2.3.4	Detecção de Objetos em Cenários com Dados Limitados	14
2.3.5	Aumento de Dados	15
2.3.6	Pré-processamento Fotométrico	16
2.3.7	Métricas de Avaliação	16
2.4	Trabalhos relacionados	17
2.4.1	Trabalho 1: <i>Automated corner grading of trading cards: Defect identification and confidence calibration through deep learning</i>	17
2.4.2	Trabalho 2: <i>TCG-AI: AI Integration in Collectibles Grading for Trading Card Games and Sport Cards</i>	18
2.4.3	Trabalho 3: <i>A transfer learning-based YOLO network for sewer defect detection in comparison to classic object detection methods</i>	18
3	DESENVOLVIMENTO	20
3.1	Metodologia experimental	20
3.1.1	Visão geral da proposta	20
3.1.2	Organização e preparação do conjunto de dados	20
3.1.3	Modelo base	21
3.1.4	Estratégias de treinamento avaliadas	21

3.1.5	Estudo de ablação	21
3.1.6	Tecnologias e ferramentas	22
3.1.7	Critérios de validação	22
3.2	Cronograma de trabalho	23
	 REFERÊNCIAS	 25

1 Introdução

O mercado de Trading Card Games (TCG), representado por franquias como Pokémon e Magic: The Gathering, deve movimentar aproximadamente 20 bilhões de dólares globalmente em 2026, com projeção de ultrapassar 76 bilhões até 2035 ([Business Research Insights, 2026](#)). Nesse mercado, o valor de uma carta está diretamente ligado ao seu estado de conservação. Para certificar essa condição e garantir a segurança das transações, consolidou-se o serviço especializado de gradação de cartas (*grading*) ([NAHAR et al., 2025](#)). A PSA, fundada em 1991, foi a pioneira em padronizar essa avaliação ao estabelecer uma escala de 10 pontos que se tornaria norma do setor, enquanto a Beckett, em 1999, introduziu subnotas para atributos individuais ([SHEN; WEI, 2025](#)). Essa metodologia baseia-se na inspeção de quatro atributos físicos: superfície (*surface*), bordas (*edges*), cantos (*corners*) e centralização (*centering*), sendo a nota final definida pela análise combinada desses fatores ([NAHAR et al., 2025](#)).

O processo de gradação, no entanto, ainda é realizado de forma predominantemente manual. Os avaliadores inspecionam cada carta com lupas e iluminação controlada, o que torna a análise demorada, sujeita à subjetividade de cada profissional e limitada em termos de escalabilidade. Além disso, o manuseio frequente durante a inspeção representa um risco à própria carta, pois o contato repetido pode causar desgastes que reduzem a nota do item avaliado. Em um mercado no qual pequenas diferenças de conservação representam grandes variações de preço, essa inconsistência tem consequências financeiras diretas ([NAHAR et al., 2025](#); [WARREN; PIMBBLETT; MBOLI, 2026](#)).

Como resposta a esses desafios, a automação baseada em visão computacional tem sido investigada como alternativa à inspeção manual. Na indústria de manufatura, sistemas de visão computacional já são utilizados para automatizar inspeções de qualidade, empregando arquiteturas de *Deep Learning* e Redes Neurais Convolucionais (CNNs) para detectar defeitos em tempo real ([ZHENG et al., 2021](#)). No entanto, a adaptação dessas abordagens ao contexto de cartas colecionáveis apresenta dificuldades específicas, como variações de iluminação, reflexos em superfícies holográficas (*foil*) e a presença de defeitos pequenos e sutis, como riscos superficiais, desgastes nas bordas, pequenas dobras e marcas de pressão, que podem apresentar baixo contraste em relação ao fundo ([NAHAR et al., 2025](#); [WARREN; PIMBBLETT; MBOLI, 2026](#)).

Outro desafio relevante está relacionado à disponibilidade de dados. Em tarefas de detecção de objetos, especialmente em domínios especializados, a obtenção de grandes volumes de dados anotados é limitada, uma vez que esses modelos dependem fortemente de *datasets* rotulados e a construção de bases de dados anotadas em larga escala é custosa e trabalhosa ([SITU et al., 2023](#)). Esse cenário contribui para problemas como *overfitting* e baixa capacidade de generalização dos modelos ([PAIANO et al., 2024](#)), motivando o uso de

estratégias como *transfer learning*, aumento de dados (*data augmentation*) e abordagens voltadas ao aprendizado com poucos exemplos.

Pesquisadores já investigaram o uso de técnicas de visão computacional para detecção de defeitos no contexto de cartas colecionáveis (WARREN; PIMBBLETT; MBOLI, 2026; NAHAR et al., 2025), porém ainda há uma carência de estudos que avaliem sistematicamente o desempenho de diferentes estratégias em cenários com baixo volume de dados nesse contexto específico. Diante disso, este trabalho propõe uma análise comparativa de estratégias de visão computacional aplicadas à detecção de defeitos em cartas TCG, conduzida sobre um *dataset* composto por 88 cartas fornecido por uma empresa brasileira especializada em graduação. Para isso, será adotado um pipeline experimental baseado no modelo YOLOv8, no qual diferentes estratégias de treinamento serão avaliadas por meio de um estudo de ablação. A partir de um modelo base, serão conduzidos experimentos controlados nos quais técnicas como *transfer learning*, aumento de dados (*data augmentation*) e métodos de pré-processamento, como fotometria, serão progressivamente incorporados, permitindo analisar o impacto de cada estratégia no desempenho do modelo. A avaliação será realizada por meio de métricas quantitativas, com o objetivo de identificar as abordagens mais eficazes em cenários com dados limitados.

1.1 Contexto

No processo de graduação de cartas colecionáveis, a avaliação do estado físico é baseada na análise de atributos visuais da carta, como superfície, bordas e cantos. Esses atributos estão diretamente relacionados à presença de defeitos, que podem incluir riscos superficiais, desgastes nas bordas (*whitening*), pequenas dobras, marcas de pressão e irregularidades de impressão (NAHAR et al., 2025; WARREN; PIMBBLETT; MBOLI, 2026). Tais imperfeições frequentemente apresentam baixa visibilidade, podendo ocorrer em regiões específicas da carta e com variações sutis de textura e cor.

Do ponto de vista computacional, a detecção desses defeitos apresenta desafios relevantes. Muitos deles possuem dimensões reduzidas e baixo contraste em relação ao fundo, dificultando sua identificação por modelos de visão computacional. Além disso, superfícies holográficas (*foil*), comuns em cartas de maior valor, introduzem reflexos e variações de iluminação que podem mascarar imperfeições ou gerar ruídos visuais, comprometendo a extração de características relevantes (WARREN; PIMBBLETT; MBOLI, 2026).

Em tarefas de visão computacional aplicadas à inspeção visual, abordagens baseadas em aprendizado profundo, como redes neurais convolucionais (CNNs) e modelos de detecção de objetos, têm sido amplamente utilizadas para identificar defeitos em diferentes domínios (ZHENG et al., 2021). No entanto, essas abordagens geralmente dependem de grandes volumes de dados anotados para alcançar bom desempenho. No contexto de cartas colecionáveis, a construção de *datasets* extensos é limitada, uma vez que a anotação de

defeitos exige conhecimento especializado e condições controladas de captura de imagem (SITU et al., 2023; NAHAR et al., 2025).

Esse cenário caracteriza um problema típico de aprendizado com poucos dados, no qual modelos tendem a sofrer com *overfitting* e baixa capacidade de generalização (PALANO et al., 2024). Como consequência, torna-se necessário o uso de estratégias específicas, como *transfer learning*, aumento de dados (*data augmentation*) e técnicas de pré-processamento, que buscam melhorar o desempenho dos modelos mesmo com conjuntos reduzidos de treinamento.

1.2 Justificativa

A anotação de defeitos em cartas colecionáveis exige conhecimento técnico especializado e envolve alto custo operacional, o que restringe a construção de bases de dados em larga escala e justifica a investigação de estratégias eficazes para treinamento com poucos exemplos (NAHAR et al., 2025; SITU et al., 2023).

No âmbito científico, os estudos existentes sobre automação da graduação de cartas TCG apresentam contribuições relevantes, mas com escopos específicos. Nahar et al. (2025) propõem um modelo baseado em *transfer learning* para graduação de cantos, alcançando 83% de acurácia, porém sobre um conjunto de 593 cartas e restrito a um único atributo de avaliação. Warren, Pimblett e Mbolli (2026) desenvolvem um pipeline híbrido com YOLOv8 para detecção localizada de defeitos, construído sobre um *dataset* de mais de 43.000 amostras obtidas com plataforma robótica proprietária. Nenhum dos dois trabalhos avalia sistematicamente o impacto relativo de diferentes estratégias de treinamento em cenários com conjuntos reduzidos de dados reais, lacuna que este trabalho se propõe a investigar com base em um conjunto real de 88 cartas fornecido por uma empresa brasileira especializada em graduação.

Na prática, os resultados desta investigação podem mostrar até que ponto estratégias como *transfer learning*, aumento de dados e pré-processamento fotométrico permanecem eficazes quando aplicadas a um conjunto reduzido de dados reais, sem depender de plataformas robóticas de captura ou de *datasets* extensos. Essa análise é relevante para contextos em que a anotação é cara, o volume de dados é limitado, pois permite avaliar em que medida essas estratégias favorecem a detecção automática de defeitos como apoio à inspeção visual (WARREN; PIMBLETT; MBOLLI, 2026; NAHAR et al., 2025; SITU et al., 2023).

1.3 Objetivos

1.3.1 Objetivo Geral

Avaliar o desempenho de estratégias de treinamento aplicadas ao modelo YOLOv8 para detecção de defeitos em cartas Pokémon TCG em cenários com baixo volume de dados.

1.3.2 Objetivos Específicos

1. Organizar e preparar um conjunto de dados de imagens de cartas Pokémon TCG, garantindo consistência nas anotações e nas condições de captura.
2. Implementar um modelo de detecção de objetos baseados na arquitetura YOLOv8 para identificação de defeitos visuais nas cartas.
3. Aplicar estratégias de treinamento voltadas a cenários com poucos dados, incluindo *transfer learning*, aumento de dados (*data augmentation*) e técnicas de pré-processamento de imagem.
4. Conduzir um estudo de ablação para analisar o impacto individual e cumulativo de cada estratégia de treinamento no desempenho do modelo.
5. Comparar o desempenho das diferentes configurações por meio de métricas quantitativas, como precisão, *recall*, F1-score e *mean Average Precision* (mAP).
6. Analisar os resultados obtidos, identificando quais combinações de estratégias apresentam melhor desempenho em cenários com conjuntos de dados limitados.

2 Revisão Bibliográfica

A revisão bibliográfica tem como finalidade apresentar o embasamento teórico do trabalho, demonstrando o conhecimento do autor sobre o tema e identificando o estado da arte. Este capítulo deve ser organizado por conceitos e temas, construindo uma linha de argumentação que sustente a proposta do trabalho.

2.1 Referencial teórico

2.1.1 Deep Learning e Redes Neurais Convolucionais

Deep Learning é uma subárea do aprendizado de máquina que utiliza redes neurais artificiais com múltiplas camadas para aprender representações de dados a partir de exemplos, sem necessidade de características projetadas manualmente (ZHENG et al., 2021). No contexto de visão computacional, as Redes Neurais Convolucionais (CNNs, do inglês *Convolutional Neural Networks*) são a arquitetura predominante para tarefas de classificação de imagens, detecção de objetos e inspeção de defeitos (HUSSAIN, 2023). As CNNs utilizam múltiplas camadas convolucionais combinadas com estruturas de agrupamento (*pooling*) para extrair padrões visuais diretamente dos pixels da imagem (HUSSAIN, 2023).

Na inspeção visual automatizada de produtos industriais, CNNs têm demonstrado resultados superiores aos métodos tradicionais na detecção de defeitos em superfícies (ZHENG et al., 2021). Esse desempenho explica sua ampla adoção em tarefas de visão computacional que exigem reconhecimento e localização de padrões visuais complexos.

2.1.2 Visão Computacional e Inspeção Visual Automatizada

A visão computacional é a área da ciência da computação que desenvolve métodos para que sistemas digitais interpretem e analisem imagens e vídeos automaticamente. Uma de suas aplicações mais relevantes na prática industrial está nos sistemas de inspeção visual automatizada (*Automated Visual Inspection* – AVI), cuja função é substituir ou apoiar a inspeção manual de qualidade em linhas de produção (ZHENG et al., 2021).

Um sistema AVI é composto, em geral, por três etapas principais: aquisição de imagem, detecção de defeitos e controle de qualidade. A etapa de aquisição utiliza câmeras digitais combinadas com sistemas de iluminação controlada para garantir contraste adequado entre as características do produto e possíveis defeitos. Em seguida, a etapa de detecção aplica algoritmos de processamento de imagem para identificar e classificar anomalias. Por fim,

os resultados são enviados ao sistema de controle de qualidade, que determina a aceitação ou rejeição do produto (ZHENG et al., 2021).

Antes da consolidação do *Deep Learning*, muitos sistemas AVI dependiam de características projetadas manualmente por especialistas, o que os tornava sensíveis a variações nas condições de aplicação (ZHENG et al., 2021). Com o avanço das CNNs, passaram a ser desenvolvidos métodos capazes de aprender padrões diretamente a partir dos dados de treinamento, superando parte das limitações dos métodos tradicionais. Na prática industrial, sistemas baseados em CNNs têm sido aplicados com sucesso na inspeção de defeitos em semicondutores, aço e tecidos, atingindo taxas de acurácia superiores a 99% em alguns casos (ZHENG et al., 2021).

2.1.3 Trading Card Games e o Mercado de Colecionismo

Entre os domínios nos quais técnicas de visão computacional podem ser aplicadas, destaca-se o mercado de cartas colecionáveis. Trading Card Games (TCGs) são jogos baseados em cartas associadas a franquias de entretenimento como Pokémon e Magic: The Gathering (NAHAR et al., 2025). Diferentemente de jogos de cartas tradicionais, cada carta em um TCG pode apresentar atributos próprios de arte, raridade e uso em jogo, o que lhe confere também valor de colecionismo individual. No caso do Pokémon TCG, essa combinação entre jogabilidade estratégica e cultura de colecionismo também se reflete na existência de um mercado secundário ativo para a compra e venda de cartas individuais (SHEN; WEI, 2025).

Nesse mercado, o valor comercial de uma carta está fortemente associado ao seu estado de conservação físico. Imperfeições como arranhões na superfície, desgaste nas bordas ou problemas de centralização podem reduzir de forma significativa o preço de mercado do item (NAHAR et al., 2025). Para padronizar essa avaliação e aumentar a confiabilidade das transações, consolidou-se a atuação de empresas especializadas em gradação de cartas (*card grading*), como a PSA (*Professional Sports Authenticator*) e a Beckett Grading Services (SHEN; WEI, 2025).

A PSA, fundada em 1991, teve papel pioneiro na padronização desse tipo de avaliação ao adotar uma escala de 10 pontos amplamente utilizada no setor, enquanto a Beckett, a partir de 1999, introduziu subnotas para atributos individuais da carta, ampliando o detalhamento do processo de gradação (SHEN; WEI, 2025). Esse modelo de avaliação padronizada tornou-se central no mercado secundário de cartas, pois permite autenticar, encapsular e classificar itens de forma mais confiável para compradores e vendedores (HECK et al., 2026).

O processo de gradação considera, em geral, quatro atributos físicos da carta: superfície (*surface*), bordas (*edges*), cantos (*corners*) e centralização (*centering*). A nota final, em uma escala de 1 a 10, resulta da análise combinada desses fatores (NAHAR et al., 2025). Cartas classificadas com notas mais altas, como *Gem Mint*, tendem a alcançar valores

substancialmente superiores aos de exemplares com notas mais baixas, em razão da maior preservação de suas características físicas (WARREN; PIMBBLETT; MBOLI, 2026; HECK et al., 2026).

2.1.4 Desafios Técnicos na Inspeção de Cartas

Apesar do potencial de aplicação de técnicas de visão computacional nesse domínio, a inspeção automatizada de cartas TCG apresenta desafios técnicos que a diferenciam da inspeção industrial convencional. O primeiro deles é a variação de iluminação durante a captura das imagens. Warren, Pimbblett e Mboli (2026) denominam esse fenômeno de *Shadow Problem*: inconsistências de brilho causadas pela geometria do equipamento de captura, pelo ângulo da câmera e por reflexos ambientais. Sem correção adequada, esses artefatos visuais degradam a qualidade da imagem e podem levar a classificações incorretas pelos modelos de graduação.

O segundo desafio são os reflexos em superfícies holográficas (*foil*). Cartas com impressão holográfica refletem luz de forma intensa e irregular, o que pode obscurecer defeitos críticos como arranhões e desgastes de superfície. Esse comportamento óptico dificulta a segmentação da imagem e compromete a precisão de modelos treinados em condições de iluminação uniforme (WARREN; PIMBBLETT; MBOLI, 2026). Para mitigar esse problema, Nahar et al. (2025) optaram por substituir câmeras convencionais por scanners de alta resolução, garantindo iluminação constante e padronizada durante a captura.

O terceiro desafio é a subjetividade inerente ao processo de avaliação manual. Como os quatro critérios de graduação — superfície, bordas, cantos e centralização — são analisados visualmente por avaliadores humanos, o resultado final tende a variar entre profissionais diferentes, especialmente em casos limítrofes (NAHAR et al., 2025). Esse fator limita a reprodutibilidade das avaliações e compromete a confiabilidade do processo em escala industrial (WARREN; PIMBBLETT; MBOLI, 2026).

Por fim, a própria natureza dos defeitos visuais em cartas TCG representa um desafio técnico adicional. Imperfeições como riscos superficiais, desgastes e pequenas dobras podem ocupar regiões muito reduzidas da imagem e, em muitos casos, apresentar contraste sutil em relação ao fundo da carta. Essa característica dificulta tanto a anotação quanto a detecção automática desses defeitos, especialmente em cenários com quantidade limitada de dados rotulados (NAHAR et al., 2025; WARREN; PIMBBLETT; MBOLI, 2026).

2.2 Metodologia da pesquisa bibliográfica

A pesquisa bibliográfica foi realizada principalmente por meio da base Google Scholar, utilizando combinações de termos em inglês diretamente relacionados aos temas centrais do trabalho. As principais expressões de busca utilizadas foram: “*transfer learning*” AND

“object detection” AND “small dataset” AND “performance evaluation”, “trading card” OR “collectible card” AND “computer vision”, “card grading” AND “automated” OR “machine learning”, “surface defect detection” AND “computer vision” AND “scratch” OR “wear” e “subpixel edge detection” AND “measurement precision” AND “computer vision”.

Foram priorizados trabalhos acadêmicos publicados entre 2021 e 2026, em língua inglesa, disponíveis em periódicos ou anais de conferências. A seleção considerou principalmente estudos revisados por pares, mas também incluiu *preprints* e *surveys* recentes quando diretamente relacionados ao problema investigado ou necessários para fundamentar conceitos técnicos específicos.

De forma complementar, também foram consultadas fontes não acadêmicas, como páginas institucionais, relatórios setoriais e matérias jornalísticas especializadas, utilizadas exclusivamente para contextualização do mercado, caracterização do domínio de aplicação e descrição de padrões de gradação de cartas. Nesses casos, também foram consideradas fontes em língua portuguesa quando relevantes para o contexto brasileiro.

A relevância de cada trabalho foi avaliada com base em sua aderência ao problema de pesquisa, isto é, a detecção automatizada de defeitos visuais em cenários com baixo volume de dados, com ênfase em aplicações de visão computacional em domínios especializados.

2.3 Fundamentos

2.3.1 Detecção de Objetos

A detecção de objetos é uma tarefa de visão computacional que combina dois problemas distintos: a classificação de objetos presentes em uma imagem e a localização precisa de cada instância por meio de caixas delimitadoras (*bounding boxes*) (HUSSAIN, 2023). Diferentemente da classificação de imagens, que atribui um único rótulo à imagem inteira, a detecção de objetos é capaz de identificar múltiplos objetos em posições diferentes, retornando para cada um deles suas coordenadas espaciais, a classe correspondente e um escore de confiança (RAMOS; SAPPA, 2025).

A qualidade de uma detecção é medida pela métrica *Intersection over Union* (IoU), que quantifica a sobreposição entre a caixa delimitadora predita e a caixa de referência (*ground truth*). O IoU é calculado como a razão entre a área de interseção e a área de união das duas caixas, assumindo valores entre 0 e 1, onde valores mais próximos de 1 indicam maior precisão de localização (PAIANO et al., 2024). A partir de um limiar de IoU predefinido, tipicamente 0,5, uma predição é classificada como verdadeiro positivo (TP) se a sobreposição for suficiente, ou como falso positivo (FP) caso contrário (RAMOS; SAPPA, 2025).

As arquiteturas de detecção de objetos são geralmente classificadas em dois grupos: detectores de dois estágios (*two-stage*) e detectores de um estágio (*one-stage*) (HUSSAIN,

2023). Os detectores de dois estágios, como a família R-CNN, dividem o processo em uma etapa de geração de propostas de regiões candidatas e uma etapa posterior de classificação e refinamento. Embora apresentem alta acurácia, esse design resulta em maior custo computacional e menor velocidade de inferência (SITU et al., 2023). Os detectores de um estágio, por sua vez, realizam a classificação e a localização em uma única passagem pela rede, obtendo melhor desempenho em tempo real com menor demanda computacional (HUSSAIN, 2023).

No contexto deste trabalho, a detecção de objetos é mais adequada do que a classificação pura porque os defeitos de interesse não precisam apenas ser reconhecidos, mas também localizados na imagem. Em cartas TCG, riscos superficiais, desgastes e pequenas dobras podem ocupar regiões específicas e reduzidas da superfície, de modo que a localização espacial do defeito é parte central da análise (WARREN; PIMBBLETT; MBOLI, 2026). Assim, a escolha por uma tarefa de detecção, e não apenas de classificação, está diretamente associada ao tipo de problema investigado.

2.3.2 Arquitetura YOLO

A família YOLO (*You Only Look Once*) representa uma das abordagens de detecção de objetos do tipo *one-stage* mais difundidas na literatura recente, destacando-se pelo equilíbrio entre velocidade de inferência e acurácia (RAMOS; SAPPA, 2025). Desde sua formulação inicial, a arquitetura trata a detecção como um problema unificado, prevendo caixas delimitadoras e probabilidades de classe diretamente a partir da imagem em uma única passagem pela rede (HUSSAIN, 2023).

Ao longo do tempo, diferentes versões da família YOLO incorporaram melhorias voltadas ao tratamento de objetos em múltiplas escalas, à otimização do treinamento e à eficiência computacional (HUSSAIN, 2023; RAMOS; SAPPA, 2025). Entre essas evoluções, versões mais recentes adotaram o paradigma *anchor-free*, reduzindo a dependência de caixas âncora pré-definidas e simplificando o ajuste do modelo a domínios específicos (RAMOS; SAPPA, 2025).

No presente trabalho, a escolha da versão YOLOv8 não se deve apenas à sua popularidade, mas à adequação de sua formulação ao problema investigado. Como os defeitos em cartas TCG podem ser pequenos, localizados e visualmente sutis, a tarefa exige um detector capaz de preservar a informação espacial do defeito e, ao mesmo tempo, operar de forma eficiente mesmo em contexto de poucos dados. Além disso, Warren, Pimblett e Mboli (2026) demonstram que modelos da família YOLO podem ser aplicados à localização de defeitos em cartas colecionáveis, o que reforça sua pertinência ao domínio estudado. Dessa forma, a adoção do YOLO neste trabalho está associada tanto à natureza da tarefa quanto à viabilidade de sua adaptação a um *dataset* reduzido com auxílio de *transfer learning*.

2.3.3 Transfer Learning

Transfer learning é uma estratégia de aprendizado de máquina que consiste em aproveitar o conhecimento adquirido por um modelo treinado em um domínio fonte para melhorar o desempenho em um domínio alvo distinto (PAIANO et al., 2024). A motivação para essa abordagem reside na observação de que modelos profundos aprendem representações hierárquicas de características visuais que tendem a ser transferíveis entre domínios, especialmente nas camadas mais rasas da rede, que capturam padrões genéricos como bordas, texturas e gradientes (SITU et al., 2023).

Na prática, o *transfer learning* em visão computacional é implementado por meio de *fine-tuning*: um modelo pré-treinado em um dataset de larga escala, como ImageNet ou COCO, tem seus pesos utilizados como ponto de partida, sendo então re-treinado total ou parcialmente sobre o dataset alvo (PAIANO et al., 2024). Essa abordagem permite que o modelo se adapte às características específicas do novo domínio sem partir de uma inicialização aleatória, reduzindo significativamente a quantidade de dados rotulados necessária para alcançar bom desempenho (SITU et al., 2023).

Em cenários com baixo volume de dados, o *transfer learning* é especialmente relevante. Modelos treinados do zero em datasets pequenos tendem a sofrer com *overfitting*, pois o número de parâmetros livres é desproporcional à quantidade de exemplos disponíveis. Ao inicializar com pesos pré-treinados, o modelo parte de uma representação já rica em padrões visuais, o que atua como uma forma de regularização implícita e melhora a capacidade de generalização (PAIANO et al., 2024). Situ et al. (2023) demonstraram que modelos YOLO com *transfer learning* a partir de backbones pré-treinados superaram consistentemente modelos treinados do zero em tarefas de detecção de defeitos com datasets reduzidos, tanto em precisão quanto em velocidade de convergência.

2.3.4 Detecção de Objetos em Cenários com Dados Limitados

A detecção de objetos em cenários com dados limitados constitui um problema relevante em visão computacional, especialmente em domínios nos quais a coleta e a anotação de imagens são custosas. Diferentemente de tarefas de classificação, a detecção exige não apenas reconhecer a classe de interesse, mas também localizar espacialmente cada instância na imagem, o que torna o aprendizado mais sensível à escassez de exemplos rotulados. Nesse contexto, a literatura recente passou a tratar esse tipo de dificuldade no âmbito mais amplo da *Low-Shot Object Detection* (LSOD), que engloba diferentes configurações de detecção em regime de dados escassos (HUANG et al., 2023).

No caso da detecção de defeitos, essa dificuldade tende a ser ainda maior, pois muitos defeitos ocupam regiões pequenas da imagem e apresentam contraste sutil em relação ao fundo. Em aplicações de inspeção visual, essa combinação entre poucos dados anotados e objetos pequenos ou pouco salientes pode comprometer a capacidade de generalização

dos detectores e aumentar o risco de *overfitting* (RAMOS; SAPPA, 2025; PAIANO et al., 2024). Por esse motivo, estratégias como *transfer learning*, aumento de dados e técnicas de pré-processamento tornam-se particularmente relevantes para viabilizar o treinamento de modelos em conjuntos reduzidos (SITU et al., 2023; PAIANO et al., 2024).

No presente trabalho, esse problema se manifesta de forma direta, uma vez que o conjunto de dados disponível é limitado e os defeitos de interesse em cartas TCG, como riscos superficiais, desgastes e pequenas dobras, podem ser visualmente sutis e ocupar regiões específicas da carta (NAHAR et al., 2025; WARREN; PIMBBLETT; MBOLI, 2026). Assim, a investigação proposta não adota um protocolo formal de *Few-Shot Object Detection*, baseado em classes-base e classes novas, mas se insere no contexto mais amplo da detecção de objetos com dados limitados, buscando avaliar como estratégias de treinamento podem contribuir para melhorar o desempenho do detector nesse cenário.

2.3.5 Aumento de Dados

O aumento de dados (*data augmentation*) é um conjunto de técnicas que busca ampliar artificialmente a diversidade do conjunto de treinamento por meio de transformações aplicadas às imagens existentes, sem a necessidade de coletar novos exemplos (PAIANO et al., 2024). O princípio subjacente é expor o modelo a variações plausíveis dos dados durante o treinamento, de modo que a representação aprendida seja mais robusta e generalizável a condições não vistas (SITU et al., 2023).

As técnicas de aumento de dados podem ser agrupadas em duas categorias principais. As transformações geométricas incluem operações como espelhamento horizontal e vertical, rotação, recorte aleatório (*random crop*) e variação de escala. Essas transformações alteram a posição e a orientação dos objetos na imagem sem modificar suas características visuais intrínsecas (PAIANO et al., 2024). As transformações fotométricas, por sua vez, modificam as propriedades de cor e iluminação da imagem, incluindo variações de brilho, contraste, saturação e adição de ruído. Essas técnicas são especialmente úteis para treinar modelos mais robustos a variações nas condições de captura (SITU et al., 2023).

Em cenários com conjuntos de dados reduzidos, o aumento de dados desempenha um papel crítico na prevenção de *overfitting*. Ao aumentar a diversidade efetiva do conjunto de treinamento, essa estratégia reduz a dependência do modelo em relação a padrões específicos dos exemplos disponíveis, favorecendo a generalização (PAIANO et al., 2024). No contexto do presente trabalho, técnicas de aumento de dados serão incorporadas ao pipeline experimental como uma das estratégias avaliadas no estudo de ablação, permitindo quantificar seu impacto isolado no desempenho do modelo.

2.3.6 Pré-processamento Fotométrico

A qualidade das imagens de entrada é um fator determinante para o desempenho de modelos de visão computacional aplicados à inspeção visual. Em condições reais de captura, variações de iluminação, sombras e inconsistências do sensor da câmera introduzem ruídos visuais que podem obscurecer defeitos críticos e comprometer a extração de características relevantes (WARREN; PIMBBLETT; MBOLI, 2026).

Warren, Pimblett e Mboli (2026) denominam esse fenômeno de *Shadow Problem*: inconsistências de brilho causadas pela geometria do equipamento de captura, pelo ângulo da câmera e por reflexos ambientais. Para mitigar esse problema, os autores implementam a técnica de *Flat Field Correction* (FFC), um método de pré-processamento amplamente utilizado em imageamento científico para normalizar a iluminação espacial e a sensibilidade por pixel do sensor. O processo consiste na captura de imagens de referência com uma superfície branca uniforme sob as mesmas condições de iluminação utilizadas para as imagens do objeto, gerando uma matriz de correção que é aplicada a cada imagem de entrada por multiplicação elemento a elemento.

Os resultados demonstram que a FFC reduz a variância da intensidade das imagens em aproximadamente 99,97%, eliminando artefatos de iluminação e preservando os detalhes reais da superfície da carta. Essa normalização é especialmente relevante para cartas TCG, cujas superfícies holográficas (*foil*) são particularmente sensíveis a variações de iluminação, podendo gerar reflexos que mascaram defeitos ou introduzem falsos positivos nos modelos de detecção. No presente trabalho, técnicas de pré-processamento fotométrico serão incorporadas ao pipeline experimental como uma das estratégias avaliadas no estudo de ablação.

2.3.7 Métricas de Avaliação

A avaliação de modelos de detecção de objetos requer métricas que considerem simultaneamente a acurácia de classificação e a qualidade de localização espacial (RAMOS; SAPP, 2025). As métricas fundamentais são a Precisão (*Precision*) e a Revocação (*Recall*), definidas respectivamente como:

$$\text{Precision} = \frac{TP}{TP + FP} \quad (2.1)$$

$$\text{Recall} = \frac{TP}{TP + FN} \quad (2.2)$$

onde TP são os verdadeiros positivos, FP os falsos positivos e FN os falsos negativos (PAIANO et al., 2024). A Precisão mede a proporção de detecções corretas entre todas as detecções realizadas, enquanto a Revocação mede a proporção de objetos reais que foram corretamente detectados. O *F1-score* combina ambas as métricas em um único valor por meio da média harmônica (PAIANO et al., 2024):

$$F1 = 2 \cdot \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (2.3)$$

A métrica principal para avaliação de detectores de objetos é o *mean Average Precision* (mAP), que resume o desempenho do modelo ao calcular a média das precisões médias (*Average Precision* – AP) para cada classe (RAMOS; SAPPA, 2025). A AP de uma classe é calculada como a área sob a curva precisão-revocação, que varia conforme o limiar de confiança das predições. O mAP é então a média das APs sobre todas as classes (PAIANO et al., 2024):

$$\text{mAP} = \frac{1}{N} \sum_{i=1}^N AP_i \quad (2.4)$$

onde N é o número de classes. Duas variantes são frequentemente reportadas na literatura: o mAP@0.5, que utiliza um limiar de IoU de 0,5 para classificar predições como TP, e o mAP@0.5:0.95, que calcula a média sobre múltiplos limiares de IoU entre 0,5 e 0,95 (RAMOS; SAPPA, 2025). No presente trabalho, o estudo de ablação utilizará o mAP@0.5 como métrica principal de comparação entre as diferentes configurações experimentais, complementado por Precision, Recall e F1-score para uma análise mais granular do desempenho de cada estratégia.

2.4 Trabalhos relacionados

Os trabalhos relacionados selecionados nesta seção foram escolhidos com base no critério de proximidade com o problema investigado neste TCC, isto é, a detecção de defeitos visuais com apoio de visão computacional em cenários de dados limitados, com aplicação à graduação de cartas colecionáveis. Embora nem todos os trabalhos estejam inseridos exatamente no mesmo domínio, todos enfrentam desafios práticos ou metodológicos muito próximos ao deste estudo, seja no contexto direto de cartas TCG, seja na comparação de estratégias de detecção de defeitos com uso de *transfer learning* e arquiteturas baseadas em YOLO.

2.4.1 Trabalho 1: *Automated corner grading of trading cards: Defect identification and confidence calibration through deep learning*

Nahar et al. (2025) abordaram o problema da automação da inspeção de defeitos em cartas colecionáveis, com foco específico na graduação de cantos, um dos critérios mais relevantes e subjetivos do processo de avaliação manual. Esse problema é diretamente relacionado ao presente trabalho, pois ambos investigam o uso de visão computacional para apoiar a identificação de defeitos visuais em cartas TCG. Para resolvê-lo, os autores propuseram um modelo baseado em *transfer learning* utilizando a arquitetura DenseNet201

para classificar defeitos em cantos de cartas em quatro níveis de severidade, além de incorporar técnicas de calibração de confiança e um mecanismo de *human-in-the-loop*. Os resultados reportaram acurácia média de 83%, posteriormente elevada para 85% após realimentação com amostras mal classificadas. No entanto, o trabalho apresenta limitações importantes: o estudo está restrito apenas ao critério de cantos, utiliza um conjunto relativamente pequeno de 593 cartas (4.744 imagens de cantos) e não realiza comparação sistemática entre diferentes estratégias de treinamento em cenários de baixo volume de dados. O presente trabalho diferencia-se por ampliar o foco para a detecção de defeitos visuais em cartas TCG em um cenário explicitamente caracterizado por poucos dados, comparando, por meio de um estudo de ablação, o impacto de diferentes estratégias de treinamento sobre o desempenho do modelo.

2.4.2 Trabalho 2: *TCG-AI: AI Integration in Collectibles Grading for Trading Card Games and Sport Cards*

Warren, Pimblett e Mboli (2026) investigam o problema da automação da graduação de cartas colecionáveis por meio de um sistema híbrido que combina técnicas clássicas de visão computacional com redes neurais convolucionais e YOLOv8 com suporte a *oriented bounding boxes*. Assim como no presente trabalho, os autores buscam reduzir a subjetividade e melhorar a consistência do processo de grading. A metodologia proposta organiza a avaliação em múltiplas etapas, cobrindo centralização, cantos, bordas, superfície e nota global, apoiada por uma plataforma robótica de captura padronizada e um grande conjunto de dados com mais de 43.000 amostras após aumento de dados. Os resultados indicam que abordagens baseadas em CNN apresentam melhor acurácia preditiva do que pipelines puramente baseados em OpenCV, enquanto o framework híbrido melhora a localização dos defeitos e a interpretabilidade das decisões. Apesar da relevância do trabalho, ele apresenta limitações para o contexto deste TCC: depende de infraestrutura proprietária de captura, trabalha com um volume muito elevado de dados e prioriza a construção de um sistema completo de grading, em vez da comparação sistemática de estratégias em contexto de poucos dados. O presente trabalho avança ao concentrar a investigação especificamente no desempenho de diferentes estratégias de treinamento em um *dataset* reduzido e real, o que o aproxima de cenários mais restritivos e comuns em aplicações que dependem de anotação especializada.

2.4.3 Trabalho 3: *A transfer learning-based YOLO network for sewer defect detection in comparison to classic object detection methods*

Situ et al. (2023) trataram do problema da detecção automática de defeitos visuais em um ambiente de inspeção, comparando uma rede YOLO com *transfer learning* contra diferentes métodos clássicos e múltiplos *backbones* pré-treinados. Embora o domínio de

aplicação seja distinto, o problema metodológico é muito próximo ao deste TCC: avaliar o impacto de diferentes estratégias e configurações de modelos de detecção em tarefas de defeito visual com limitação prática de dados rotulados. Para isso, os autores utilizaram uma YOLO_v2 associada a 11 CNNs pré-treinadas e a compararam com quatro detectores tradicionais (R-CNN, Fast R-CNN, Faster R-CNN e SSD), medindo precisão de detecção, tempo computacional e IoU. Os resultados mostraram que os métodos baseados em YOLO com *transfer learning* superaram os demais detectores, e que o uso de *transfer learning* foi necessário para melhorar o desempenho em cenários com dados rotulados limitados ou ambientes desafiadores. A principal limitação do estudo, no entanto, está na distância de domínio em relação ao presente trabalho, já que o experimento foi conduzido com defeitos em redes de esgoto e não em cartas colecionáveis. Ainda assim, o trabalho é altamente relevante por oferecer uma referência metodológica sólida para comparação entre arquiteturas, *backbones* e estratégias de treinamento. O presente trabalho diferencia-se por transferir esse raciocínio comparativo para o domínio específico de cartas Pokémon TCG, com ênfase na análise de defeitos sutis e na avaliação de estratégias em um cenário real de baixo volume de dados.

Uma tabela comparativa ajuda a sintetizar as diferenças entre os trabalhos:

Tabela 1 – Comparação entre trabalhos relacionados

Critério	Nahar2025	Warren2026	Situ2023	Este trabalho
Objetivo	Graduação automática de cantos	Sistema híbrido de grading completo	Comparação de YOLO + TL para defeitos	Comparação de estratégias em low-data para cartas TCG
Tecnologia	DenseNet201 + TL + calibração	OpenCV + CNN + YOLOv8-OBB	YOLO_v2 + 11 CNNs pré-treinadas + TL	YOLO + TL + augmentation + pré-processamento
Validação	Acurácia e calibração de confiança	Acurácia, localização e consistência de grading	Precisão, tempo computacional e IoU	Precisão, recall, F1-score e mAP
Limitação	Restrito a cantos e dataset pequeno	Dataset grande e infraestrutura proprietária	Domínio diferente do problema de cartas	—

Fonte: Elaborado pelo autor (2026)

3 Desenvolvimento

Neste capítulo, apresenta-se a metodologia experimental proposta para o desenvolvimento do trabalho no TCC2, bem como o cronograma previsto para a execução das etapas planejadas.

3.1 Metodologia experimental

3.1.1 Visão geral da proposta

A proposta deste trabalho consiste no desenvolvimento de um pipeline experimental para detecção de defeitos visuais em cartas Pokémon TCG utilizando o modelo YOLOv8. O objetivo não é construir um sistema completo de gradação automática, mas avaliar, em um cenário com baixo volume de dados, como diferentes estratégias de treinamento influenciam o desempenho do detector.

O recorte metodológico adotado concentra-se na identificação de defeitos superficiais visíveis na imagem, como riscos, desgastes e pequenas dobras, por serem compatíveis com a formulação do problema como tarefa de detecção de objetos. Critérios de gradação que exigem tratamento geométrico próprio, como centralização, não integram o escopo experimental desta etapa.

A investigação será conduzida sobre um conjunto de 88 cartas fornecido por uma empresa brasileira especializada em gradação. A partir desse conjunto, será construída uma base de experimentação compatível com o formato exigido pelo YOLOv8, permitindo comparar, de forma controlada, diferentes estratégias de treinamento em contexto de dados limitados.

3.1.2 Organização e preparação do conjunto de dados

A primeira etapa do desenvolvimento consistirá na organização e preparação do conjunto de dados. Nessa fase, as imagens serão revisadas quanto à qualidade, padronizadas em nomenclatura e estrutura de diretórios, e convertidas para o formato de anotação compatível com o YOLOv8. Caso necessário, também será feita a revisão das anotações existentes, buscando garantir consistência entre as classes de defeitos consideradas e as respectivas caixas delimitadoras.

Após essa etapa, o conjunto será particionado em subconjuntos de treino, validação e teste. Como se trata de um cenário com quantidade reduzida de amostras, o particionamento será feito de modo a preservar, na medida do possível, a representatividade das classes

presentes em cada subconjunto. Além disso, o mesmo particionamento será mantido em todos os experimentos, a fim de garantir comparabilidade entre as configurações avaliadas.

3.1.3 Modelo base

Como modelo de detecção será utilizada a versão YOLOv8, selecionada por seu equilíbrio entre eficiência computacional e desempenho em tarefas de detecção de objetos. O modelo base servirá como referência para o estudo de ablação, permitindo avaliar de forma incremental a contribuição de cada estratégia de treinamento.

Inicialmente, será definida uma configuração base do YOLOv8 com parâmetros fixos de treinamento. Entre os parâmetros mantidos constantes ao longo dos experimentos estão resolução de entrada, número de épocas, taxa de aprendizado, tamanho do lote e critério de parada. Os valores finais desses hiperparâmetros serão estabelecidos a partir de testes preliminares, mas permanecerão iguais em todas as configurações experimentais para que a comparação entre elas seja válida.

3.1.4 Estratégias de treinamento avaliadas

O trabalho comparará três estratégias principais de treinamento em cenário de poucos dados: *transfer learning*, aumento de dados (*data augmentation*) e pré-processamento fotométrico.

O *transfer learning* será empregado por meio do ajuste fino (*fine-tuning*) de pesos pré-treinados, buscando aproveitar representações visuais previamente aprendidas em bases de larga escala. Essa estratégia será comparada à configuração base para verificar em que medida o uso de pesos pré-treinados melhora o desempenho do detector em um conjunto reduzido de imagens.

O aumento de dados será utilizado para ampliar artificialmente a variabilidade do conjunto de treinamento. Serão consideradas transformações compatíveis com o problema, como ajustes geométricos e fotométricos, desde que preservem a interpretação visual dos defeitos e não distorçam suas características essenciais.

Já o pré-processamento fotométrico terá como objetivo reduzir o impacto de variações de iluminação e reflexos presentes nas imagens, especialmente em cartas com superfícies holográficas. Essa etapa buscará tornar as imagens mais consistentes do ponto de vista visual antes do treinamento, contribuindo para a extração de características mais estáveis pelo modelo.

3.1.5 Estudo de ablação

A comparação entre as estratégias será realizada por meio de um estudo de ablação cumulativo. Nesse tipo de desenho experimental, parte-se de uma configuração base e, em

seguida, novas estratégias são incorporadas de forma progressiva, permitindo observar a contribuição individual e cumulativa de cada uma delas.

Serão consideradas quatro configurações experimentais principais:

1. YOLOv8 base;
2. YOLOv8 com *transfer learning*;
3. YOLOv8 com *transfer learning* e aumento de dados;
4. YOLOv8 com *transfer learning*, aumento de dados e pré-processamento fotométrico.

Esse desenho foi escolhido por ser compatível com o escopo do TCC1 e por permitir uma análise clara da influência de cada estratégia em um contexto de baixo volume de dados. Em vez de comparar múltiplas arquiteturas, a proposta fixa o modelo YOLOv8 e concentra a investigação naquilo que constitui a contribuição principal do trabalho: a comparação entre estratégias de treinamento.

3.1.6 Tecnologias e ferramentas

A implementação será realizada em Python, linguagem amplamente utilizada em projetos de visão computacional e aprendizado profundo. Para o treinamento do modelo, será utilizada a biblioteca oficial da família YOLOv8. O processamento das imagens e as etapas de preparação do conjunto de dados poderão ser apoiados por bibliotecas de manipulação de imagens e visão computacional, como OpenCV. Para a aplicação de transformações de aumento de dados, poderão ser utilizadas bibliotecas específicas de *augmentation*, desde que compatíveis com o pipeline definido.

Os experimentos serão executados em ambiente computacional com suporte a GPU, de modo a reduzir o tempo de treinamento e viabilizar a execução das diferentes configurações previstas no estudo de ablação.

3.1.7 Critérios de validação

A validação do desempenho do modelo será feita por meio de métricas quantitativas utilizadas em tarefas de detecção de objetos. A métrica principal será o *mean Average Precision* com limiar de IoU de 0,5 (mAP@0.5), por permitir uma visão sintética do desempenho do detector em termos de classificação e localização.

Como métricas complementares, também serão utilizados precisão, *recall* e F1-score, com o objetivo de fornecer uma análise mais detalhada do comportamento do modelo em cada configuração experimental. A comparação entre os experimentos buscará identificar quais estratégias produzem ganhos mais consistentes no cenário de dados limitados considerado neste trabalho.


3.2 Cronograma de trabalho

O cronograma a seguir apresenta, no formato de diagrama de Gantt, as atividades previstas para o desenvolvimento do TCC2, distribuídas ao longo das semanas do semestre.

Instruções para personalização do cronograma:

- Ajuste o número de semanas conforme o calendário acadêmico do semestre;
- Modifique as atividades de acordo com as etapas do seu projeto;
- Os marcos (*milestones*) indicam entregas importantes — adapte-os às datas de avaliação;
- As setas entre atividades indicam dependências — uma atividade só inicia após a conclusão da anterior;
- Utilize o diagrama como ferramenta de acompanhamento: atualize-o a cada reunião com o orientador.

Figura 1 – Cronograma de atividades – Diagrama de Gantt



Fonte: Elaborado pelo autor (2026)

Referências

- Business Research Insights. *Collectible Card Game Market Size, Share, Growth, Trends, Global Industry Analysis*. 2026. Acesso em: 15 mar. 2026. Disponível em: <<https://www.businessresearchinsights.com/market-reports/collectible-card-game-market-101837>>. 5
- HECK, J. et al. Sales characteristics of pokémon trading cards: A prospective one-year field study. *PLOS One*, v. 21, n. 3, p. 334289, 2026. 10, 11
- HUANG, Q. et al. A survey of deep learning for low-shot object detection. *ACM Computing Surveys*, v. 56, n. 5, p. 1–37, 2023. 14
- HUSSAIN, M. YOLO-v1 to YOLO-v8, the rise of YOLO and its complementary nature toward digital manufacturing and industrial defect detection. *Machines*, v. 11, n. 7, p. 677, 2023. 9, 12, 13
- NAHAR, L. et al. Automated corner grading of trading cards: Defect identification and confidence calibration through deep learning. *Computers in Industry*, v. 164, p. 104187, 2025. 5, 6, 7, 10, 11, 15, 17
- PAIANO, M. et al. Transfer learning with generative models for object detection on limited datasets. *Machine Learning: Science and Technology*, v. 5, n. 3, p. 035041, 2024. 5, 7, 12, 14, 15, 16, 17
- RAMOS, L. T.; SAPPA, A. D. A decade of you only look once (yolo) for object detection: A review. *IEEE Access*, v. 13, p. 192747–192794, 2025. 12, 13, 15, 16, 17
- SHEN, Q.; WEI, C. Business model innovation in the trading card grading industry: Cross-national insights from pokémon trading card game and non-fungible tokens. *Asian Journal of Business and Strategic Perspectives*, v. 2, n. 2, 2025. Disponível em: <<https://doi.org/10.70122/ajbsp.v2i2.37>>. 5, 10
- SITU, Z. et al. A transfer learning-based yolo network for sewer defect detection in comparison to classic object detection methods. *Developments in the Built Environment*, v. 15, p. 100191, 2023. 5, 7, 13, 14, 15, 18
- WARREN, L.; PIMBBLETT, K.; MBOLI, J. TCG-AI: AI integration in collectibles grading for trading card games and sport cards. *Research Square*, 2026. Preprint. 5, 6, 7, 11, 13, 15, 16, 18
- ZHENG, X. et al. Recent advances in surface defect inspection of industrial products using deep learning techniques. *The International Journal of Advanced Manufacturing Technology*, 2021. 5, 6, 9, 10